TRƯỜNG ĐẠI HỌC NAM CẦN THƠ
KHOA CÔNG NGHỆ THÔNG TIN

HUỲNH TRỌNG NGỮ

TÊN ĐỀ TÀI

HỆ THỐNG HỖ TRỢ CHẨN ĐOÁN BỆNH LÝ TIM MẠCH QUA TÍN HIỆU ECG BẰNG CNN

BÁO CÁO ĐỒ ÁN CƠ SỞ 2

Ngành: Công Nghệ Thông Tin

Mã số ngành: 7480201

Cần thơ, 03 - 2026

TRƯỜNG ĐẠI HỌC NAM CẦN THƠ

KHOA CÔNG NGHỆ THÔNG TIN

SINH VIÊN THỰC HIỆN

HUỲNH TRỌNG NGỮ

MSSV: 220854

KHÓA 10

TÊN ĐỀ TÀI

HỆ THỐNG HỖ TRỢ CHẨN ĐOÁN BỆNH LÝ TIM MẠCH QUA TÍN HIỆU ECG 12 CHUYỂN ĐẠO BẰNG TRÍ TUỆ NHÂN TẠO

BÁO CÁO ĐỒ ÁN CƠ SỞ 2

Ngành: Khoa học máy tính

Mã số ngành: 7480201

GIẢNG VIÊN HƯỚNG DẪN

TRẦN VĂN THIỆN

Cần thơ, 03 - 2026

LỜI CẢM TẠ

Với lòng biết ơn sâu sắc và tình cảm chân thành em xin gửi lời cảm ơn tới:

Trường Đại học Nam Cần Thơ, khoa Công Nghệ Thông Tin, cùng các giảng viên đã tận tình chỉ dạy và tạo điều kiện giúp đỡ em trong quá trình học tập, nghiên cứu đề tài.

Đặc biệt, em xin gửi lời cảm ơn chân thành và sâu sắc đến thầy TS. Trần Văn Thiện**,** người đã luôn tận tình theo sát, hướng dẫn, chỉ dạy, giúp đỡ và động viên em trong suốt quá trình nghiên cứu đề tài này. Em trân trọng sự tâm huyết, sự kiên nhẫn và những định hướng quý báu mà thầy đã dành cho em – không chỉ là sự chỉ dẫn về mặt học thuật mà còn là nguồn động lực giúp em vượt qua những khó khăn trong quá trình thực hiện đề tài.

Xin gửi lời cảm ơn đến những thầy cô đang công tác và giảng dạy tại Trường Đại học Nam Cần Thơ và một số thầy cô khác đã tận tình truyền đạt kiến thức quý báu, hỗ trợ cho em trong những năm học vừa qua.

Đồng thời, em cũng xin cảm ơn các bạn bè của em đã hỗ trợ, góp ý về nội dung và hình thức trong quá trình nghiên cứu đề tài.

Mặc dù đã cố gắng rất nhiều nhưng do kiến thức còn hạn chế nên không tránh khỏi những thiếu sót trong quá trình thực hiện đề tài. Vì thế, em rất mong nhận được những ý kiến đóng góp từ quý thầy cô để em có thêm những kinh nghiệm hoàn thiện hơn cho công việc chuyên môn của em trong tương lai.

Em xin chân thành cảm ơn! Trân trọng

Cần Thơ, ngày tháng năm 2026

Sinh viên thực hiện

Huỳnh Trọng Ngữ

LỜI CAM KẾT

Tôi xin cam kết nội dung khóa luận này được hoàn thành dựa trên các kết quả nghiên cứu của của cá nhân tôi và các kết quả này chưa được dùng cho bất cứ đồ án cùng cấp nào khác. Và những kết quả đạt được hoàn thành dựa trên các kết quả nghiên cứu của tôi trong khuôn khổ của của đề tài *"HỆ THỐNG HỖ TRỢ CHẨN ĐOÁN BỆNH LÝ TIM MẠCH QUA TÍN HIỆU ECG CNN"* được trình bày trong quyển báo cáo nghiên cứu này.

Cần Thơ, ngày tháng năm 2026

Sinh viên thực hiện

Huỳnh Trọng Ngữ

NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Cần Thơ, ngày tháng 03 năm 2026

Giảng viên hướng dẫn

Trần Văn Thiện

MỤC LỤC

CHƯƠNG 1: GIỚI THIỆU 1
1.1 Lý do chọn đề tài 1
1.2 Mục tiêu nghiên cứu 2
1.3 Đối Tượng và phạm vi nghiên cứu 2
1.4 Bố cục đồ án 3
CHƯƠNG 2: TỔNG QUAN ĐỀ TÀI VÀ CƠ SỞ LÝ THUYẾT 4
2.1 Tổng quan về tín hiệu Điện tâm đồ (ECG) 12 chuyển đạo 4
2.1.1 Khái niệm và ý nghĩa lâm sàng của ECG 4
2.1.2. Các bệnh lý tim mạch thường gặp trên ECG 4
2.2. Cơ sở lý thuyết về Học sâu (Deep Learning) trong xử lý chuỗi thời gian 5
2.2.1. Mạng nơ-ron tích chập (CNN) và cấu trúc Multi-scale CNN (công thức Tích chập 1D) 5
2.2.2. Cơ chế Self-Attention và kiến trúc Transformer (công thức Multi-Head Attention) 5
2.2.3. Vấn đề mất cân bằng dữ liệu và Hàm mất mát Asymmetric Focal Loss (công thức Asymmetric Focal Loss) 6
2.3. Tổng quan bộ dữ liệu PhysioNet Challenge 2020 6
2.3.1. Nguồn gốc và đặc điểm bộ dữ liệu 6
2.3.2. Cấu trúc nhãn SNOMED CT và hệ thống 27 nhãn phân loại 7
CHƯƠNG 3: PHÂN TÍCH THIẾT KẾ HỆ THỐNG 8
3.1 Phân tích yêu cầu hệ thống 8
3.1.1. Yêu cầu chức năng 8
3.1.2. Yêu cầu phi chức năng 8
3.2. Thiết kế luồng dữ liệu và phân rã chức năng 9
3.2.1. Sơ đồ phân rã chức năng BFD 9
3.2.2. Sơ đồ luồng dữ liệu ngữ cảnh - DFD mức 0 11
3.2.3. Sơ đồ luồng dữ liệu chi tiết - DFD mức 1 11
3.3. Thiết kế luồng hoạt động và quy trình nghiệp vụ 13

3.3.1. Sơ đồ quy trình tổng quát của hệ thống 13
3.3.2. Sơ đồ hoạt động chức năng tải tín hiệu và dự đoán 15
3.3.3. Sơ đồ tuần tự luồng tiền xử lý và inference 17
3.3.4. Sơ đồ kiến trúc thành phần hệ thống 19
3.3.5. Sơ đồ triển khai hệ thống 21
CHƯƠNG 4: XÂY DỰNG MÔ HÌNH CARDIAC AI V4 23
4.1. Tiền xử lý tín hiệu điện tim 23
4.1.1. Trích xuất tín hiệu đa kênh và chuẩn hóa 23
4.1.2. Kỹ thuật đệm/cắt tín hiệu 23
4.1.3. Tăng cường dữ liệu bằng Gaussian Noise và Amplitude Scaling 24
4.1.4. Phân chia tập dữ liệu huấn luyện và kiểm thử 24
4.2. Đề xuất kiến trúc mạng kết hợp CNN và Transformer 25
4.2.1. Thiết kế khối MultiScaleConvBlock với 4 nhánh trích xuất đặc trưng 25
.4.2.2. Thiết kế khối Transformer Encoder với cơ chế Self-Attention 26
4.2.3. Xây dựng Classification Head cho phân loại đa nhãn 27
4.3. Thiết lập tham số và tiến trình huấn luyện 28
4.3.1. Cấu hình siêu tham số (Hyperparameters) và Kỹ thuật Gradient Accumulation 28
4.3.2. Lịch trình học Cosine (Cosine Annealing LR) 30
4.3.3. Tiến trình Warmup và Fine-tuning toàn mô hình 30
CHƯƠNG 5: KẾT QUẢ THỰC NGHIỆM VÀ ĐÁNH GIÁ 32
5.1 Môi trường thực nghiệm và độ đo đánh giá 32
5.1.1. Cấu hình môi trường thực nghiệm 32
5.1.2. Các độ đo đánh giá hiệu năng 32
5.2. Chiến lược tối ưu ngưỡng phân loại (Thresholding) 33
5.2.1. Chiến lược 1: Dựa trên chỉ số Youden (Youden Index) 33
5.2.2. Chiến lược 2: Tối ưu F1 với ràng buộc y tế (Ràng buộc Recall ³ 0.75) 34
5.2.3. Chiến lược 3: Ngưỡng sàng lọc (Screening) 35

5.3. Phân tích kết quả thực nghiệm.....36
5.3.1. So sánh hiệu năng giữa các chiến lược phân ngưỡng.....36
5.3.2. Đánh giá chi tiết hiệu suất trên từng nhãn bệnh lý.....38
5.3.3. Phân tích diện tích dưới đường cong ROC và PR.....40
5.4 Đánh giá tổng kết và Giao diện kết quả (Inference TTA 5x).....42
5.4.1. Đánh giá tính ứng dụng của mô hình V4.....42
5.4.2. Minh họa dự đoán trên mẫu thử nghiệm lâm sàng.....44
CHƯƠNG 6: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN.....46
6.1 Các kết quả đã đạt được của đề tài.....46
6.2 Các hạn chế còn tồn tại.....47
6.3 Hướng phát triển trong tương lai.....48
6.4 Đề xuất.....49
KẾT LUẬN.....51
TÀI LIỆU THAM KHẢO.....53

DANH MỤC BẢNG

Bảng 4. 1. Phân chia tập dữ liệu huấn luyện, kiểm định và kiểm thử.....25

Bảng 5. 1. So sánh phương pháp và hiệu năng giữa Cardiac AI V4 và các nghiên cứu liên quan.....43

DANH MỤC HÌNH

Hình 3. 1. Sơ đồ phân rã chức năng hệ thống (BFD).....10

Hình 3. 2. Sơ đồ luồng dữ liệu ngữ cảnh - DFD mức 0.....11

Hình 3. 3. Sơ đồ luồng dữ liệu chi tiết - DFD mức 1.....12

Hình 3. 4. Quy trình Tiền xử lý Dữ liệu ECG và Phân chia Tập Dữ liệu (80/10/10) — PhysioNet Challenge 2020.....14

Hình 3. 5. Kiến trúc Mô hình V4: MULTI-SCALE CNN + TRANSFORMER.....16

Hình 3. 6. Quy trình huấn luyện 2 Giai đoạn (Warmup → Fine-tune).....18

Hình 3. 7. Quy trình Inference và tối ưu ngưỡng phân loại.....20

Hình 3. 8. Kết quả đánh giá toàn diện trên tập test.....22

Hình 5. 1. Biểu đồ so sánh hiệu năng các chỉ số đo lường theo 3 chiến lược phân ngưỡng.....36

Hình 5. 2. Biểu đồ Radar/Heatmap thể hiện hiệu suất phân loại trên 27 nhãn bệnh lý tim mạch.....38

Hình 5. 3. Đường cong ROC (trái) và PR (phải) đánh giá hiệu năng tổng thể của Cardiac AI V4.....40

Hình 5. 4. Giao diện trực quan của hệ thống Cardiac AI V4 minh họa kết quả chẩn đoán đa nhãn trên ca lâm sàng thực tế.....45

DANH MỤC TỪ VIẾT TẮT

AI	:	Artificial Intelligence	Trí tuệ nhân tạo
API	:	Application Programming Interface	Giao diện lập trình ứng dụng
CNNs	:	Convolutional Neural Network	Mạng nơ-ron tích chập
ANN	:	Approximate Nearest Neighbor	Mạng nơ-ron nhân tạo
AF	:	Atrial Fibrillation	Rung nhĩ
AFL		Atrial Flutter	Cuồng nhĩ
ASL	:	Asymmetric Focal Loss	Hàm mất mát Asymmetric Focal
AUC	:	Area Under the ROC Curve	Diện tích dưới đường cong ROC
CVDs	:	Cardiovascular Diseases	Bệnh lý tim mạch
ECG	:	Electrocardiogram	Điện tâm đồ
EMR	:	Electronic Medical Record	Bệnh án điện tử
FN	:	False Negative	Âm tính giả (Bỏ sót ca bệnh)
FP	:	False Positive	Dương tính giả (Cảnh báo nhầm)
FPR	:	False Positive Rate	Tỷ lệ dương tính giả
GANs	:	Generative Adversarial Networks	Mạng đối nghịch sinh
HIS	:	Hospital Information System	Hệ thống Thông tin Bệnh viện
HL7	:	Health Level Seven	Chuẩn giao tiếp y tế quốc tế HL7
LAD	:	Left Axis Deviation	Lệch trục trái
LBBB	:	Left Bundle Branch Block	Block nhánh trái (Blốc nhánh trái)

mAP	:	Mean Average Precision	Độ chính xác trung bình
MHSA	:	Multi-Head Self-Attention	Cơ chế tự chú ý đa đầu
LQT	:	Prolonged QT Interval	Khoảng QT kéo dài
PACS	:	Picture Archiving and Communication System	Hệ thống lưu trữ, truyền tải hình ảnh
PR	:	Precision-Recall	Biểu đồ đánh giá Độ chính xác - Độ nhạy
PVC	:	Premature Ventricular Contraction	Ngoại tâm thu thất
RAD	:	Right Axis Deviation	Lệch trục phải
RBBB	:	Right Bundle Branch Block	Block nhánh phải
ROC	:	Receiver Operating Characteristic	Đường cong đặc trưng hoạt động
SaMD	:	Software as a Medical Device	Phần mềm là Thiết bị Y tế
SB	:	Sinus Bradycardia	Nhịp chậm xoang
SNOMED CT	:	Systematized Nomenclature of Medicine - Clinical Terms	Chuẩn thuật ngữ lâm sàng quốc tế
SNR	:	Sinus Rhythm	Nhịp xoang bình thường
STach	:	Sinus Tachycardia	Nhịp nhanh xoang
TN	:	True Negative	Âm tính thật
TP	:	True Positive	Dương tính thật
TPR	:	True Positive Rate	Tỷ lệ dương tính thật (Độ nhạy / Sensitivity)
TTA	:	Test-Time Augmentation	Kỹ thuật tăng cường dữ liệu thời gian kiểm thử
VPB	:	Ventricular Premature Beats	Nhịp sớm thất
WFDB	:	Waveform Database	Định dạng chuẩn dữ liệu dạng sóng y khoa

CHƯƠNG 1
GIỚI THIỆU

1.1 Lý do chọn đề tài

Bệnh lý tim mạch (Cardiovascular Diseases - CVDs) hiện đang là một trong những nguyên nhân gây tử vong hàng đầu trên toàn cầu cũng như tại Việt Nam. Việc phát hiện và chẩn đoán sớm các bất thường về tim mạch đóng vai trò sống còn trong việc giảm thiểu tỷ lệ tử vong và nâng cao hiệu quả điều trị. Trong thực tiễn lâm sàng, Điện tâm đồ (ECG - Electrocardiogram) 12 chuyển đạo được xem là "tiêu chuẩn vàng" và là công cụ phổ biến nhất, cung cấp cái nhìn toàn diện về hoạt động điện sinh lý của tim từ nhiều góc độ khác nhau.

Tuy nhiên, việc phân tích thủ công và đồng thời 12 kênh tín hiệu ECG là một thách thức lớn. Quá trình này đòi hỏi bác sĩ phải có chuyên môn cao và dạn dày kinh nghiệm để nhận diện chính xác các vi điểm (như sóng P, phức bộ QRS, sóng T) cũng như các bất thường ẩn sâu trong tín hiệu. Trên thực tế, tại các tuyến y tế cơ sở, sự thiếu hụt các chuyên gia tim mạch thường dẫn đến tình trạng chẩn đoán thiếu nhất quán, dễ bỏ sót bệnh lý hoặc chẩn đoán nhầm. Thêm vào đó, một bệnh nhân trong thực tế hoàn toàn có thể mắc đồng thời nhiều bệnh lý tim mạch khác nhau (bài toán phân loại đa nhãn - multi-label), làm tăng tính phức tạp cho quá trình chẩn đoán thủ công.

Trong những năm gần đây, sự phát triển bùng nổ của Trí tuệ nhân tạo (AI), đặc biệt là các mô hình Học sâu (Deep Learning), đã mở ra những hướng tiếp cận mới mang tính đột phá trong việc tự động hóa phân tích dữ liệu y tế. Dù vậy, nhiều hệ thống hiện tại vẫn chỉ dừng lại ở việc phân tích trên 1 chuyển đạo đơn lẻ hoặc chỉ chẩn đoán một vài loại bệnh cơ bản, chưa tận dụng hết thông tin không gian từ 12 chuyển đạo, đồng thời thiếu đi các cơ chế kiểm soát rủi ro an toàn y tế (như việc ưu tiên không bỏ sót các ca bệnh nguy hiểm).

Nhận thấy những hạn chế đó, kết hợp với niềm đam mê nghiên cứu ứng dụng công nghệ thông tin vào giải quyết các bài toán y tế thực tiễn, em quyết định chọn đề tài: "*HỆ THỐNG HỖ TRỢ CHẨN ĐOÁN BỆNH LÝ TIM MẠCH QUA TÍN HIỆU ECG BẰNG CNN"* làm đồ án tốt nghiệp.

Đề tài tập trung nghiên cứu và phát triển kiến trúc mô hình tiên tiến kết hợp giữa Multi-scale CNN (nhằm trích xuất các đặc trưng cục bộ ở nhiều góc độ thời gian ngắn - trung - dài) và Transformer (nhằm bắt giữ các mối liên hệ ngữ cảnh tổng thể) trên bộ dữ liệu chuẩn lâm sàng PhysioNet Challenge 2020. Mục tiêu cốt lõi của hệ thống không chỉ là chẩn đoán đồng thời 27 nhãn bệnh lý tim mạch, mà còn đặc biệt chú trọng vào tính an toàn lâm sàng thông qua việc thiết lập chiến lược

ngưỡng tối ưu, đảm bảo độ nhạy (Recall) cao đối với 6 nhóm bệnh lý đặc biệt nguy hiểm (AF, AFL, LBBB, PVC, LQT, VPB). Hệ thống kỳ vọng sẽ trở thành một công cụ đắc lực, hỗ trợ các bác sĩ đưa ra quyết định nhanh chóng, chính xác và nhất quán hơn, góp phần nâng cao chất lượng chăm sóc sức khỏe cộng đồng.

1.2 Mục tiêu nghiên cứu

Mục tiêu bao quát của đề tài là nghiên cứu, thiết kế và xây dựng thành công một hệ thống Trí tuệ nhân tạo (AI) có khả năng phân tích tự động tín hiệu Điện tâm đồ (ECG) 12 chuyển đạo nhằm hỗ trợ chẩn đoán chính xác và đồng thời 27 bệnh lý tim mạch khác nhau. Để hiện thực hóa mục tiêu này, đề tài tiến hành trích xuất và tiền xử lý chuẩn hóa bộ dữ liệu lâm sàng đa nhãn phức tạp PhysioNet/Computing in Cardiology Challenge 2020. Trọng tâm của nghiên cứu là việc đề xuất và xây dựng kiến trúc Học sâu tiên tiến (Cardiac AI V4), kết hợp linh hoạt giữa mạng Multi-scale CNN – bao gồm 4 nhánh song song giúp trích xuất đặc trưng cục bộ ở nhiều dải tần khác nhau – và mạng Transformer nhằm mô hình hóa các mối liên hệ ngữ cảnh dài hạn trên toàn bộ chuỗi tín hiệu. Đồng thời, hệ thống ứng dụng hàm mất mát Asymmetric Focal Loss kết hợp trọng số lớp (class weights) để giải quyết triệt để bài toán mất cân bằng dữ liệu y tế.

Bên cạnh việc nâng cao hiệu suất nhận diện, điểm nhấn đặc biệt của đề tài còn nằm ở việc tối ưu hóa tính an toàn lâm sàng thông qua chiến lược phân ngưỡng (Thresholding). Cụ thể, hệ thống tối ưu hóa chỉ số F1 nhưng đặt ra ràng buộc khắt khe về độ nhạy ($Recall \geq 0.75$)đối với 6 nhóm bệnh lý đặc biệt nguy hiểm (AF, AFL, LBBB, PVC, LQT, VPB) nhằm giảm thiểu tối đa rủi ro bỏ sót ca bệnh. Cuối cùng, hiệu năng của mô hình được đánh giá toàn diện qua các độ đo chuẩn như Macro F1, Micro F1, AUC, mAP và tích hợp kỹ thuật Test-Time Augmentation (TTA 5x) trong quy trình suy luận, qua đó đảm bảo tính ổn định và độ tin cậy cao của hệ thống khi triển khai hỗ trợ các y bác sĩ trong thực tiễn.

1.3 Đối Tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu cốt lõi của đề tài là tín hiệu Điện tâm đồ (ECG) 12 chuyển đạo và các đặc trưng nhận diện của 27 loại bệnh lý tim mạch dựa trên hệ thống phân loại chuẩn SNOMED CT. Bên cạnh đó, đề tài đi sâu vào nghiên cứu các công nghệ Học sâu (Deep Learning) tiên tiến, đặc biệt là cấu trúc và cơ chế hoạt động của mạng nơ-ron tích chập đa tỷ lệ (Multi-scale CNN) trong việc trích xuất đặc trưng không gian cục bộ, kết hợp cùng kiến trúc Transformer để xử lý chuỗi thời gian và nắm bắt ngữ cảnh dài hạn. Đồng thời, nghiên cứu cũng tập trung vào việc tối ưu hóa mô hình thông qua hàm mất mát Asymmetric Focal Loss xử lý bài toán mất cân bằng dữ liệu y tế, cùng các thuật toán phân ngưỡng (Thresholding) nhằm tối ưu hóa các độ đo chẩn đoán an toàn lâm sàng.

Để đảm bảo tính khả thi và tập trung chuyên sâu, phạm vi nghiên cứu của đồ án được giới hạn rõ ràng về mặt dữ liệu, kỹ thuật và ứng dụng. Về mặt dữ liệu, đề tài chỉ sử dụng bộ dữ liệu công khai chuẩn lâm sàng PhysioNet/Computing in Cardiology Challenge 2020, tiến hành huấn luyện và đánh giá trên 37.749 bản ghi ECG hợp lệ mà không thu thập thêm dữ liệu mới từ các bệnh viện thực tế. Về mặt kỹ thuật, mô hình Cardiac AI V4 được thiết kế bằng ngôn ngữ Python với framework PyTorch và huấn luyện hoàn toàn trên nền tảng điện toán đám mây Kaggle với tài nguyên GPU Tesla P100. Về mặt ứng dụng, hệ thống được phát triển với mục tiêu hoạt động như một công cụ hỗ trợ quyết định lâm sàng dành cho y bác sĩ, hoàn toàn không thay thế chuyên gia y tế. Tiêu chuẩn an toàn của hệ thống được giới hạn ở việc đảm bảo ràng buộc độ nhạy ($Recall \geq 0.75$)đối với đúng 6 nhóm bệnh lý có nguy cơ cao (AF, AFL, LBBB, PVC, LQT, VPB).

1.4 Bố cục đồ án

Đồ án được tổ chức thành phần Mở đầu, phần Kết luận và 4 chương nội dung chính, đi từ tổng quan lý thuyết đến thiết kế hệ thống, xây dựng mô hình và đánh giá kết quả thực nghiệm.

Chương 1 giới thiệu tổng quan về đề tài, trình bày cơ sở lý thuyết về tín hiệu ECG 12 chuyển đạo, các công nghệ Học sâu cốt lõi như mạng nơ-ron tích chập (CNN) và Transformer, cũng như phân tích chi tiết đặc điểm của bộ dữ liệu PhysioNet Challenge 2020.

Chương 2 tập trung vào việc phân tích và thiết kế hệ thống, bao gồm các yêu cầu chức năng, phi chức năng, và diễn giải chi tiết thông qua các sơ đồ luồng dữ liệu, sơ đồ phân rã chức năng cùng quy trình hoạt động nghiệp vụ tổng quát.

Chương 3 đi sâu vào quá trình xây dựng và phát triển mô hình Cardiac AI V4, trình bày chi tiết từ bước tiền xử lý tín hiệu, kiến trúc mạng kết hợp Multi-scale CNN và Transformer, cho đến việc thiết lập các siêu tham số và tiến trình huấn luyện.

Chương 4 trình bày các kết quả thực nghiệm và đánh giá hệ thống, phân tích sâu về hiệu năng của các chiến lược tối ưu ngưỡng phân loại, so sánh kết quả trên từng nhãn bệnh lý thông qua các biểu đồ trực quan, đồng thời đưa ra những đánh giá tổng kết về tính ứng dụng của mô hình trong thực tiễn.

CHƯƠNG 2

TỔNG QUAN ĐỀ TÀI VÀ CƠ SỞ LÝ THUYẾT

2.1 Tổng quan về tín hiệu Điện tâm đồ (ECG) 12 chuyển đạo

2.1.1 Khái niệm và ý nghĩa lâm sàng của ECG

Điện tâm đồ (Electrocardiogram - ECG) là đồ thị ghi lại các biến thiên của dòng điện sinh lý trong tim phát sinh trong từng chu kỳ co bóp. Hệ thống ECG 12 chuyển đạo (12-lead ECG) bao gồm 6 chuyển đạo chi (I, II, III, aVR, aVL, aVF) và 6 chuyển đạo trước tim (V1 đến V6), cung cấp 12 góc nhìn không gian khác nhau về hoạt động điện của cơ tim. Mỗi chu kỳ tim bình thường trên đồ thị ECG được cấu thành từ các thành phần sóng cơ bản bao gồm sóng P (thể hiện quá trình khử cực tâm nhĩ), phức bộ QRS (thể hiện quá trình khử cực tâm thất) và sóng T (thể hiện quá trình tái cực tâm thất). Trong thực tiễn lâm sàng, ECG 12 chuyển đạo được công nhận rộng rãi là "tiêu chuẩn vàng" không xâm lấn, an toàn và chi phí thấp để đánh giá chức năng tim. Sự biến đổi về biên độ, hình dạng, khoảng thời gian giữa các sóng (như khoảng PR, khoảng QT) hoặc sự chênh lệch của đoạn ST cung cấp những căn cứ y khoa vững chắc giúp bác sĩ phát hiện kịp thời các bất thường về nhịp tim, rối loạn dẫn truyền, phì đại cơ tim hay các hội chứng thiếu máu cục bộ và nhồi máu cơ tim.

2.1.2. Các bệnh lý tim mạch thường gặp trên ECG

Hệ thống tim mạch có thể chịu ảnh hưởng bởi nhiều loại bệnh lý khác nhau, và đặc điểm nhận diện của chúng trên tín hiệu ECG thường rất đa dạng và phức tạp. Trong phạm vi bộ dữ liệu PhysioNet Challenge 2020, nghiên cứu tiến hành phân loại đồng thời 27 bệnh lý tim mạch phổ biến dựa trên chuẩn mã hóa y tế quốc tế SNOMED CT. Các nhãn bệnh lý này trải dài từ những bất thường nhẹ như nhịp chậm xoang (Bradycardia), lệch trục trái/phải (LAD/RAD) cho đến các rối loạn nhịp và dẫn truyền nghiêm trọng. Đặc biệt, đồ án đặt trọng tâm kiểm soát rủi ro an toàn lâm sàng cao nhất đối với 6 nhóm bệnh lý có tính chất nguy hiểm cấp tính, dễ dẫn đến các biến chứng đe dọa tính mạng như đột quỵ hoặc ngừng tim đột ngột. Nhóm bệnh lý nguy hiểm này bao gồm Rung nhĩ (AF - Atrial Fibrillation) và Cuồng nhĩ (AFL - Atrial Flutter) gây rối loạn huyết động và huyết khối; Blốc nhánh trái (LBBB - Left Bundle Branch Block) thường che lấp các dấu hiệu nhồi máu cơ tim cấp; Ngoại tâm thu thất (PVC - Premature Ventricular Contraction) và Nhịp sớm thất (VPB - Ventricular Premature Beats) có thể kích hoạt nhịp nhanh thất; cùng với Khoảng QT kéo dài (LQT - Prolonged QT Interval) tiềm ẩn rủi ro xoắn đỉnh. Việc nhận diện chính xác và không bỏ sót các dấu hiệu vi tế của 6 nhóm bệnh lý này trên ECG là một bài toán đầy thách thức nhưng mang ý nghĩa sống

còn, định hình trực tiếp chiến lược ràng buộc độ nhạy (Recall) khắt khe trong việc phát triển mô hình AI của đồ án.

2.2. Cơ sở lý thuyết về Học sâu (Deep Learning) trong xử lý chuỗi thời gian

2.2.1. Mạng nơ-ron tích chập (CNN) và cấu trúc Multi-scale CNN (công thức Tích chập 1D)

Trong xử lý chuỗi thời gian tĩnh như tín hiệu điện tâm đồ, Mạng nơ-ron tích chập (Convolutional Neural Network - CNN) dạng một chiều (1D CNN) đóng vai trò then chốt trong việc tự động trích xuất các đặc trưng không gian cục bộ. Cơ sở toán học của lớp tích chập 1D được biểu diễn qua công thức:

$$(x * w)(i) = \sum_{j} x(i+j) \cdot w(j)$$

, trong đó tín hiệu đầu vào x được trượt qua bởi một bộ lọc (kernel) w để tính toán tích chập và tạo ra các bản đồ đặc trưng (feature maps). Tuy nhiên, đặc thù của tín hiệu ECG là các bất thường có thể xuất hiện ở những chu kỳ thời gian rất khác nhau; ví dụ như phức bộ QRS diễn ra rất nhanh và hẹp, trong khi đoạn ST hoặc sóng T lại kéo dài hơn. Do đó, kiến trúc CNN truyền thống với một kích thước bộ lọc cố định thường gặp hạn chế trong việc bao quát toàn bộ các biến đổi này. Để khắc phục, đề tài áp dụng cấu trúc Multi-scale CNN với thiết kế nhiều nhánh tích chập hoạt động song song. Việc sử dụng đồng thời các bộ lọc có kích thước lớn, trung bình và nhỏ trên cùng một tín hiệu đầu vào giúp mô hình thu thập trọn vẹn từ các biến thiên vi mô cho đến xu hướng vĩ mô của chuỗi thời gian, tạo ra bộ biểu diễn đặc trưng toàn diện trước khi đưa vào các tầng phân tích sâu hơn.

2.2.2. Cơ chế Self-Attention và kiến trúc Transformer (công thức Multi-Head Attention)

Mặc dù Multi-scale CNN xử lý rất tốt các đặc trưng cục bộ, nhưng khả năng nắm bắt sự phụ thuộc xa (long-range dependencies) trên toàn bộ chiều dài chuỗi tín hiệu lại là thế mạnh đặc hữu của kiến trúc Transformer. Trái tim của kiến trúc này là cơ chế tự chú ý (Self-Attention), cho phép mô hình tự động đánh giá mức độ quan trọng và thiết lập mối liên kết giữa bất kỳ hai mốc thời gian nào trong đoạn tín hiệu, bất kể khoảng cách giữa chúng xa đến đâu. Để tăng cường khả năng biểu diễn, hệ thống sử dụng cơ chế Multi-Head Attention, được định nghĩa toán học thông qua việc tính toán đồng thời nhiều không gian chú ý:

$$\text{Attention}(Q,K,V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

Thông qua cơ chế này, thay vì xử lý tuần tự từng bước như mạng nơ-ron hồi quy (RNN) truyền thống, Transformer có thể nhìn nhận toàn cục chuỗi tín hiệu trong một lần tính toán ma trận. Sự kết hợp giữa khả năng trích xuất hình thái đa tỷ lệ của CNN và tầm nhìn không gian - thời gian toàn cục của Transformer tạo ra một mạng nơ-ron lai mạnh mẽ, đặc biệt phù hợp để phát hiện các quy luật rối loạn nhịp tim tiềm ẩn rải rác.

2.2.3. Vấn đề mất cân bằng dữ liệu và Hàm mất mát Asymmetric Focal Loss (công thức Asymmetric Focal Loss)

Một trong những thách thức cốt lõi khi áp dụng Học sâu vào bài toán chẩn đoán y tế là sự mất cân bằng dữ liệu nghiêm trọng, trong đó số lượng mẫu của các bệnh lý hiếm gặp thường chiếm tỷ lệ vô cùng nhỏ so với dữ liệu nhịp tim bình thường. Đối với bài toán phân loại đa nhãn nhiều lớp, việc sử dụng hàm mất mát Cross-Entropy truyền thống sẽ khiến mô hình bị áp đảo bởi các lớp đa số và dần bỏ qua việc học các đặc trưng của lớp thiểu số. Để giải quyết triệt để rào cản này, hệ thống áp dụng hàm mất mát Asymmetric Focal Loss (ASL). Đây là một biến thể tối ưu, cho phép tách biệt hoàn toàn việc phạt lỗi giữa các dự đoán dương tính (positive) và âm tính (negative) thông qua hai tham số hội tụ riêng biệt $. .

Công thức toán học của Asymmetric Focal Loss được biểu diễn cơ bản dưới dạng

$$\mathrm{L} = -\sum \left(y\,(1-p)^{\gamma_+} \log(p) + (1-y)\,p^{\gamma_-} \log(1-p) \right)$$

Nhờ cơ chế bất đối xứng đặc biệt này, mô hình có thể chủ động triệt tiêu sự ảnh hưởng của hàng loạt các mẫu âm tính dễ đoán, đồng thời tập trung trọng số gradient vào việc phân tích các mẫu dương tính khó đoán của những bệnh lý hiếm gặp. Đây chính là nền tảng toán học đảm bảo hệ thống có thể đạt được độ nhạy lâm sàng cao đối với các ca bệnh nguy hiểm dù tần suất xuất hiện trong tập dữ liệu là rất thấp.

2.3. Tổng quan bộ dữ liệu PhysioNet Challenge 2020

2.3.1. Nguồn gốc và đặc điểm bộ dữ liệu

Bộ dữ liệu PhysioNet/Computing in Cardiology Challenge 2020 là một trong những cơ sở dữ liệu lâm sàng quy mô lớn và chuẩn mực nhất hiện nay dành cho nghiên cứu phân tích tín hiệu Điện tâm đồ (ECG) 12 chuyển đạo. Được tổng hợp từ nhiều nguồn y tế và bệnh viện trên toàn thế giới, bộ dữ liệu cung cấp một cái nhìn đa dạng về các biến thể sinh lý cũng như nhiễu động thường gặp trong môi trường khám chữa bệnh thực tế. Trong phạm vi của đồ án, sau quá trình trích xuất và loại bỏ các mẫu không đạt yêu cầu, hệ thống sử dụng tổng cộng 37.749 bản ghi ECG hợp lệ để tiến hành phân chia tập huấn luyện và đánh giá. Mỗi bản ghi được lưu trữ dưới định

dạng chuẩn WFDB (Waveform Database), bao gồm một tệp tin tín hiệu dạng ma trận (.mat) chứa dữ liệu biên độ điện thế của đồng thời 12 chuyển đạo và một tệp tin tiêu đề (.hea) chứa các thông tin siêu dữ liệu (metadata) cùng các mã gán nhãn lâm sàng. Toàn bộ các tín hiệu đầu vào đều được chuẩn hóa về tần số lấy mẫu 500Hz, tạo điều kiện thuận lợi và đồng nhất cho việc áp dụng các kỹ thuật trích xuất đặc trưng bằng mạng nơ-ron học sâu.

2.3.2. Cấu trúc nhãn SNOMED CT và hệ thống 27 nhãn phân loại

Điểm khác biệt và cũng là thách thức lớn nhất của bộ dữ liệu PhysioNet 2020 nằm ở hệ thống gán nhãn y khoa vô cùng phức tạp dựa trên chuẩn thuật ngữ lâm sàng quốc tế SNOMED CT (Systematized Nomenclature of Medicine - Clinical Terms). Thay vì chỉ chẩn đoán một bệnh lý duy nhất (phân loại đơn nhãn), mỗi bản ghi ECG trong bộ dữ liệu hoàn toàn có thể được gán đồng thời nhiều mã SNOMED CT khác nhau, phản ánh chân thực tình trạng mắc đa bệnh lý phức tạp thường thấy ở bệnh nhân tim mạch. Hệ thống tập trung giải quyết bài toán phân loại này đối với danh sách 27 nhãn bệnh lý có tính điểm (scored labels) đã được hội đồng y khoa chuyên môn thẩm định. Các nhãn này bao phủ một phổ trạng thái lâm sàng rộng lớn, từ nhịp xoang bình thường (SNR), các rối loạn nhịp và dẫn truyền phổ biến, cho đến 6 nhóm bệnh lý nguy hiểm mang tính cấp cứu cao đã được xác định trước đó (AF, AFL, LBBB, PVC, LQT, VPB). Việc chuẩn hóa nhãn phân loại theo mã SNOMED CT không chỉ giúp mô hình AI định hướng học tập các đặc trưng y khoa chính xác mà còn tạo ra nền tảng tương thích vững chắc để hệ thống có thể dễ dàng tích hợp vào các nền tảng bệnh án điện tử (EMR) tại các cơ sở y tế trong tương lai.

CHƯƠNG 3
PHÂN TÍCH THIẾT KẾ HỆ THỐNG

3.1 Phân tích yêu cầu hệ thống

3.1.1. Yêu cầu chức năng

Yêu cầu chức năng của hệ thống được xác định dựa trên quy trình thao tác thực tế của bác sĩ chuyên khoa khi phân tích điện tâm đồ, nhằm đảm bảo phần mềm có thể trở thành một công cụ hỗ trợ liền mạch và hiệu quả. Đầu tiên, hệ thống cần cung cấp khả năng tiếp nhận và đọc dữ liệu đầu vào là các bản ghi tín hiệu ECG 12 chuyển đạo tuân theo định dạng chuẩn WFDB, bao gồm tệp tin tín hiệu thô (.mat) và tệp tin thông tin bệnh án (.hea). Ngay sau khi tiếp nhận, hệ thống phải tự động thực hiện module tiền xử lý tín hiệu, bao gồm các bước chuẩn hóa phân phối (z-score normalization) độc lập cho từng chuyển đạo và kỹ thuật cắt gọt hoặc đệm zero (crop/pad) để đưa toàn bộ chuỗi thời gian về độ dài tiêu chuẩn 4096 mẫu. Chức năng phân tích cốt lõi yêu cầu hệ thống nạp các trọng số của mô hình Cardiac AI V4 và thực hiện quy trình suy luận (inference) kết hợp kỹ thuật tăng cường dữ liệu thời gian kiểm thử (TTA 5x), từ đó xuất ra vector xác suất dự đoán cho 27 nhãn bệnh lý tim mạch. Cuối cùng, hệ thống phải tích hợp bộ cấu hình ngưỡng tối ưu y tế để chuyển đổi xác suất thành kết quả chẩn đoán nhị phân, phân loại mức độ cảnh báo lâm sàng từ bình thường đến nguy hiểm, đồng thời kết xuất đồ thị trực quan hóa tín hiệu 12 chuyển đạo cùng biểu đồ phân bố xác suất nhằm cung cấp luận cứ minh bạch cho người sử dụng.

3.1.2. Yêu cầu phi chức năng

Bên cạnh các nghiệp vụ cốt lõi, hệ thống AI trong y tế đòi hỏi phải đáp ứng các tiêu chuẩn khắt khe về yêu cầu phi chức năng để đảm bảo tính an toàn, độ tin cậy và khả năng vận hành thực tế. Về mặt hiệu năng chẩn đoán, tiêu chí tối thượng là hệ thống không được phép đánh đổi sự an toàn của bệnh nhân lấy điểm số đánh giá tổng thể; cụ thể, mô hình bắt buộc phải duy trì độ nhạy (Recall) lớn hơn hoặc bằng 0.75 đối với 6 nhóm bệnh lý có nguy cơ tử vong cấp tính cao, trong khi vẫn phải đảm bảo mức độ F1-score tổng quát ổn định. Về mặt tốc độ xử lý và phản hồi, toàn bộ luồng pipeline từ lúc tải file dữ liệu, thực hiện tiền xử lý, chạy 6 vòng dự đoán (1 bản gốc và 5 bản augment) cho đến khi hiển thị kết quả trực quan phải được hoàn tất trong thời gian tính bằng giây, yêu cầu sự tối ưu hóa cao về thao tác tính toán ma trận trên thiết bị tăng tốc phần cứng (GPU). Về tính linh hoạt và khả năng mở rộng, kiến trúc của hệ thống cần được thiết kế theo hướng phân tách rõ ràng giữa module học sâu (.pth) và module cấu hình nghiệp vụ (.json), cho phép các kỹ sư dễ dàng cập nhật bộ ngưỡng phân loại mới hoặc đóng gói toàn bộ luồng xử lý thành các API độc lập để tích hợp vào hệ thống Thông tin Bệnh viện (HIS) trong tương lai.

3.2. Thiết kế luồng dữ liệu và phân rã chức năng

3.2.1. Sơ đồ phân rã chức năng BFD

Sơ đồ phân rã chức năng (Business Function Diagram - BFD) thể hiện cấu trúc phân cấp các nhóm nghiệp vụ cốt lõi mà hệ thống AI chẩn đoán điện tâm đồ cần thực hiện. Đứng ở mức tổng quát nhất, toàn bộ hệ thống được chia thành ba nhóm chức năng chính bao gồm quản lý tiền xử lý dữ liệu, cốt lõi phân tích học sâu và kết xuất báo cáo lâm sàng. Phân rã sâu hơn vào nhóm chức năng tiền xử lý, hệ thống chịu trách nhiệm tiếp nhận các tệp tin định dạng chuẩn WFDB, sau đó thực hiện các bước chuẩn hóa z-score và đệm/cắt tín hiệu để tạo ra cấu trúc tensor đầu vào đồng nhất. Ở nhóm chức năng phân tích trung tâm, hệ thống thực hiện nạp trọng số mô hình đã huấn luyện, khởi chạy kỹ thuật tăng cường dữ liệu thời gian kiểm thử (TTA 5x) để tạo ra các biến thể tín hiệu có thêm nhiễu và độ lệch biên độ, từ đó tính toán trung bình cộng để xuất ra ma trận xác suất dự đoán ban đầu. Cuối cùng, chức năng kết xuất báo cáo đảm nhận việc đối chiếu xác suất với bộ ngưỡng y tế nhằm đưa ra kết luận nhị phân, phân loại mức độ cảnh báo đối với 6 bệnh lý nguy hiểm và vẽ các biểu đồ trực quan hóa tín hiệu để trả về cho người dùng.

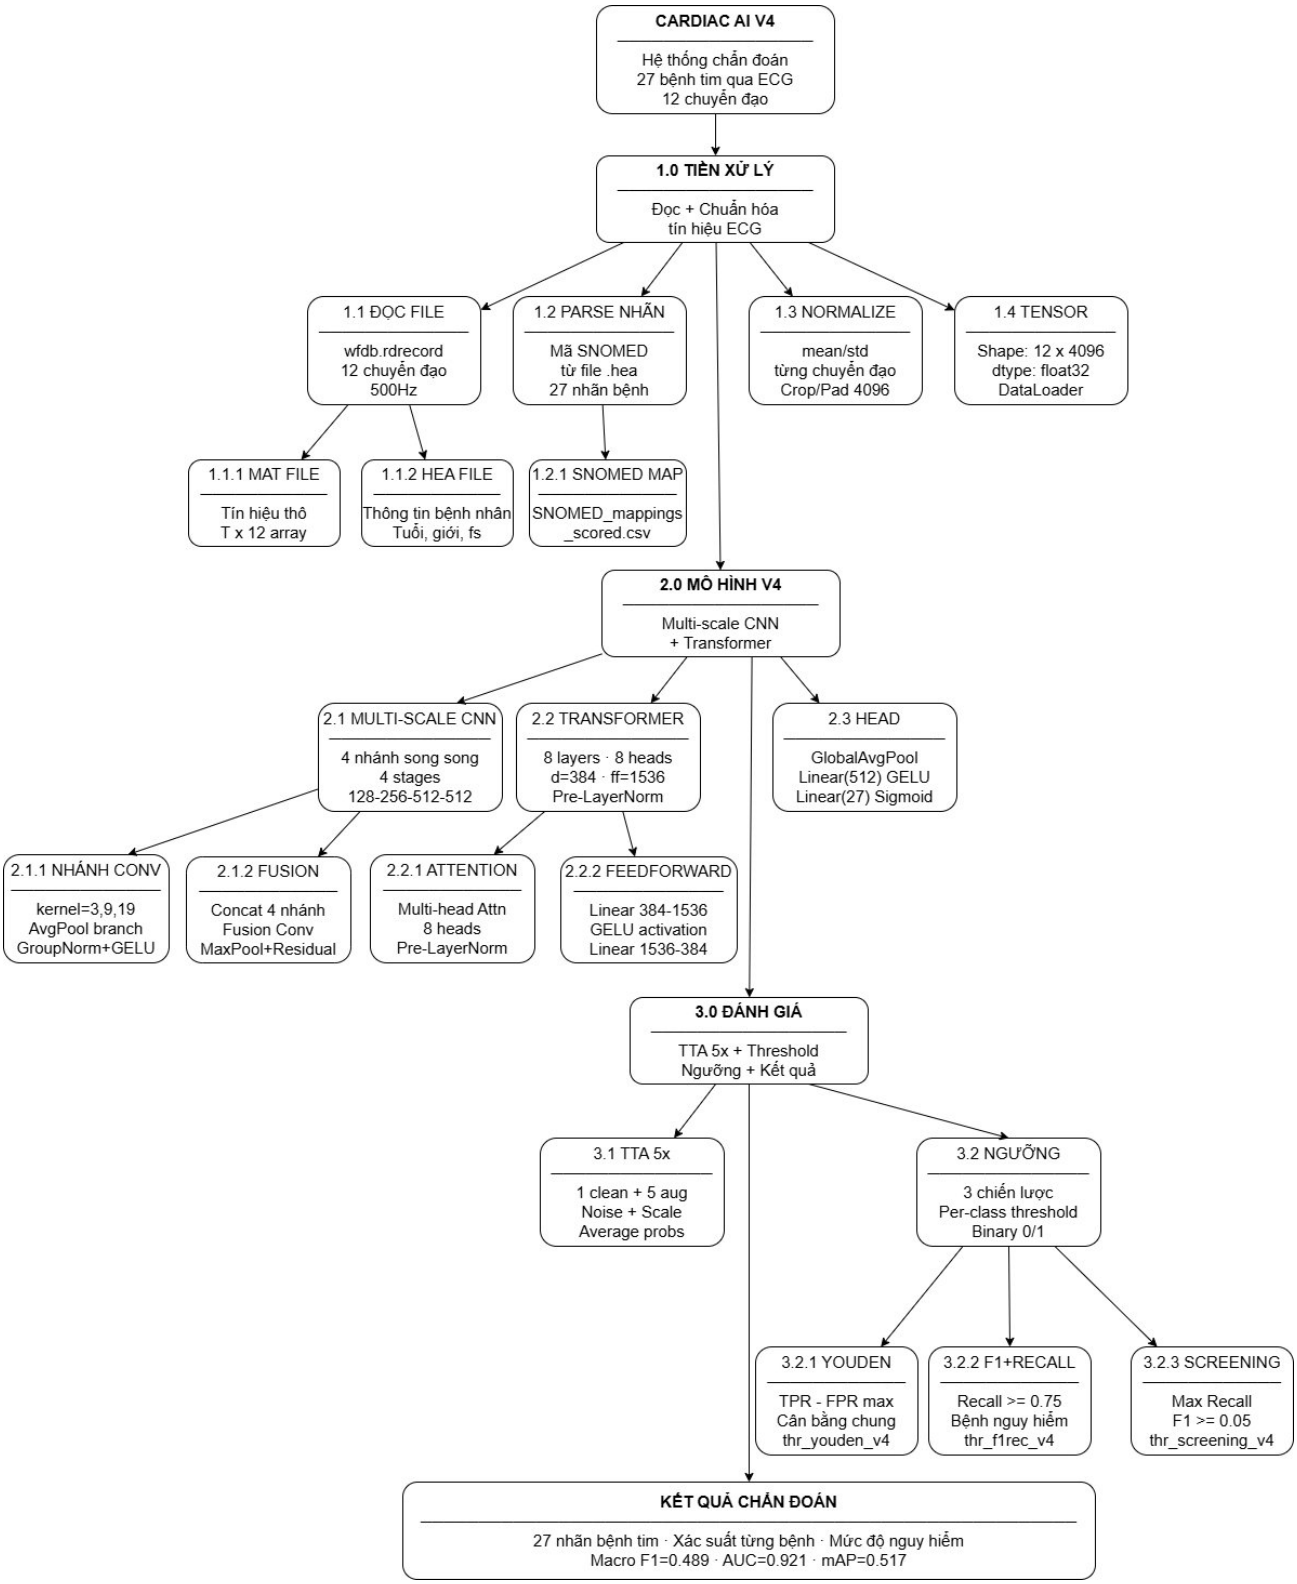

Hình 3. 1. Sơ đồ phân rã chức năng hệ thống (BFD)

3.2.2. Sơ đồ luồng dữ liệu ngữ cảnh - DFD mức 0

Sơ đồ luồng dữ liệu ngữ cảnh (Data Flow Diagram Level 0) mô tả bức tranh giao tiếp tổng thể và xác định rõ ranh giới của hệ thống so với môi trường bên ngoài. Trong mô hình này, hệ thống chẩn đoán Cardiac AI V4 được đặt ở vị trí trung tâm như một tiến trình xử lý duy nhất, tương tác trực tiếp với một tác nhân bên ngoài là y bác sĩ hoặc nhân viên y tế. Luồng dữ liệu đầu vào bắt đầu khi người dùng tải lên bộ hồ sơ điện tâm đồ thô của bệnh nhân, bao gồm tín hiệu điện thế từ file .mat và các thông tin siêu dữ liệu đi kèm từ file .hea. Hệ thống trung tâm sẽ đóng vai trò như một "hộp đen" đối với người dùng, tự động thực hiện toàn bộ các tính toán ma trận phức tạp bên trong. Ngay sau khi quá trình phân tích hoàn tất, luồng dữ liệu đầu ra sẽ trả ngược lại cho người dùng một báo cáo y khoa toàn diện, bao gồm danh sách các bệnh lý được phát hiện trong số 27 nhãn tiêu chuẩn, mức độ cảnh báo lâm sàng tương ứng và các đồ thị sinh động hỗ trợ cho quá trình ra quyết định cuối cùng của bác sĩ.

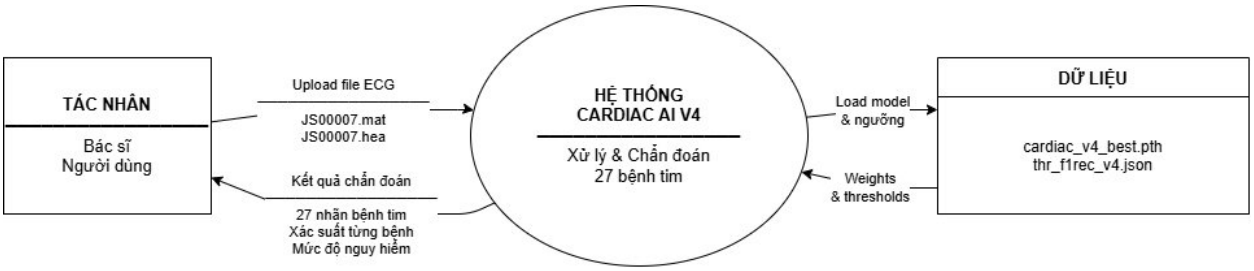

Hình 3. 2. Sơ đồ luồng dữ liệu ngữ cảnh - DFD mức 0

3.2.3. Sơ đồ luồng dữ liệu chi tiết - DFD mức 1

Tiến hành phân rã tiến trình trung tâm của sơ đồ ngữ cảnh, Sơ đồ luồng dữ liệu mức 1 (DFD Level 1) làm rõ các bước chuyển hóa dữ liệu qua từng phân hệ và sự tương tác với các kho lưu trữ (Data Stores) bên trong. Dữ liệu thô từ người dùng trước tiên đi vào tiến trình tiền xử lý để được làm sạch và định hình thành tensor có kích thước chuẩn (1, 12, 4096). Tensor này tiếp tục chảy vào tiến trình suy luận học sâu; tại đây, hệ thống sẽ truy xuất kho lưu trữ mô hình để nạp file trọng số tốt nhất (cardiac_v4_best.pth) chứa các tham số của mạng Multi-scale CNN và Transformer. Mảng xác suất thô (raw probabilities) sinh ra từ tiến trình này ngay lập tức được chuyển sang tiến trình phân ngưỡng và cảnh báo. Tiến trình này thực hiện thao tác truy xuất vào kho lưu trữ cấu hình ngưỡng y tế (thr_f1rec_v4.json) để đối chiếu xác suất sinh ra với mức ngưỡng tối ưu đã được ràng buộc độ nhạy ($Recall \geq 0.75$)cho các bệnh nguy hiểm. Dữ liệu sau khi đi qua tiến trình này sẽ biến đổi thành các nhãn chẩn đoán rời rạc và luồng dữ liệu cuối cùng sẽ được đưa vào module đồ họa để kết xuất thành giao diện hiển thị trả về cho người dùng.

Hình 3. 3. Sơ đồ luồng dữ liệu chi tiết - DFD mức 1

3.3. Thiết kế luồng hoạt động và quy trình nghiệp vụ

3.3.1. Sơ đồ quy trình tổng quát của hệ thống

Sơ đồ quy trình tổng quát cung cấp góc nhìn toàn cảnh về chuỗi thao tác nghiệp vụ từ thời điểm bắt đầu đến khi kết thúc một phiên chẩn đoán. Ban đầu, người dùng khởi tạo phiên làm việc bằng cách chuẩn bị và tải lên hồ sơ bệnh án điện tâm đồ định dạng chuẩn WFDB. Ngay khi tiếp nhận yêu cầu, hệ thống kích hoạt luồng kiểm tra tính hợp lệ của tệp dữ liệu; nếu phát hiện lỗi định dạng hoặc thiếu sót thông tin, một thông báo từ chối sẽ được trả về yêu cầu người dùng thao tác lại. Khi dữ liệu đã được xác thực, luồng quy trình tự động chuyển tiếp sang giai đoạn tiền xử lý tín hiệu và gọi hàm suy luận từ mô hình AI cốt lõi. Kết quả đầu ra sau đó đi qua bộ lọc cấu hình ngưỡng y tế để định hình thành các chẩn đoán cụ thể và hệ thống tiến hành xuất báo cáo chi tiết trực quan ra màn hình, đồng thời cung cấp tùy chọn cho phép người dùng lưu trữ hoặc in ấn kết quả trước khi kết thúc quy trình.

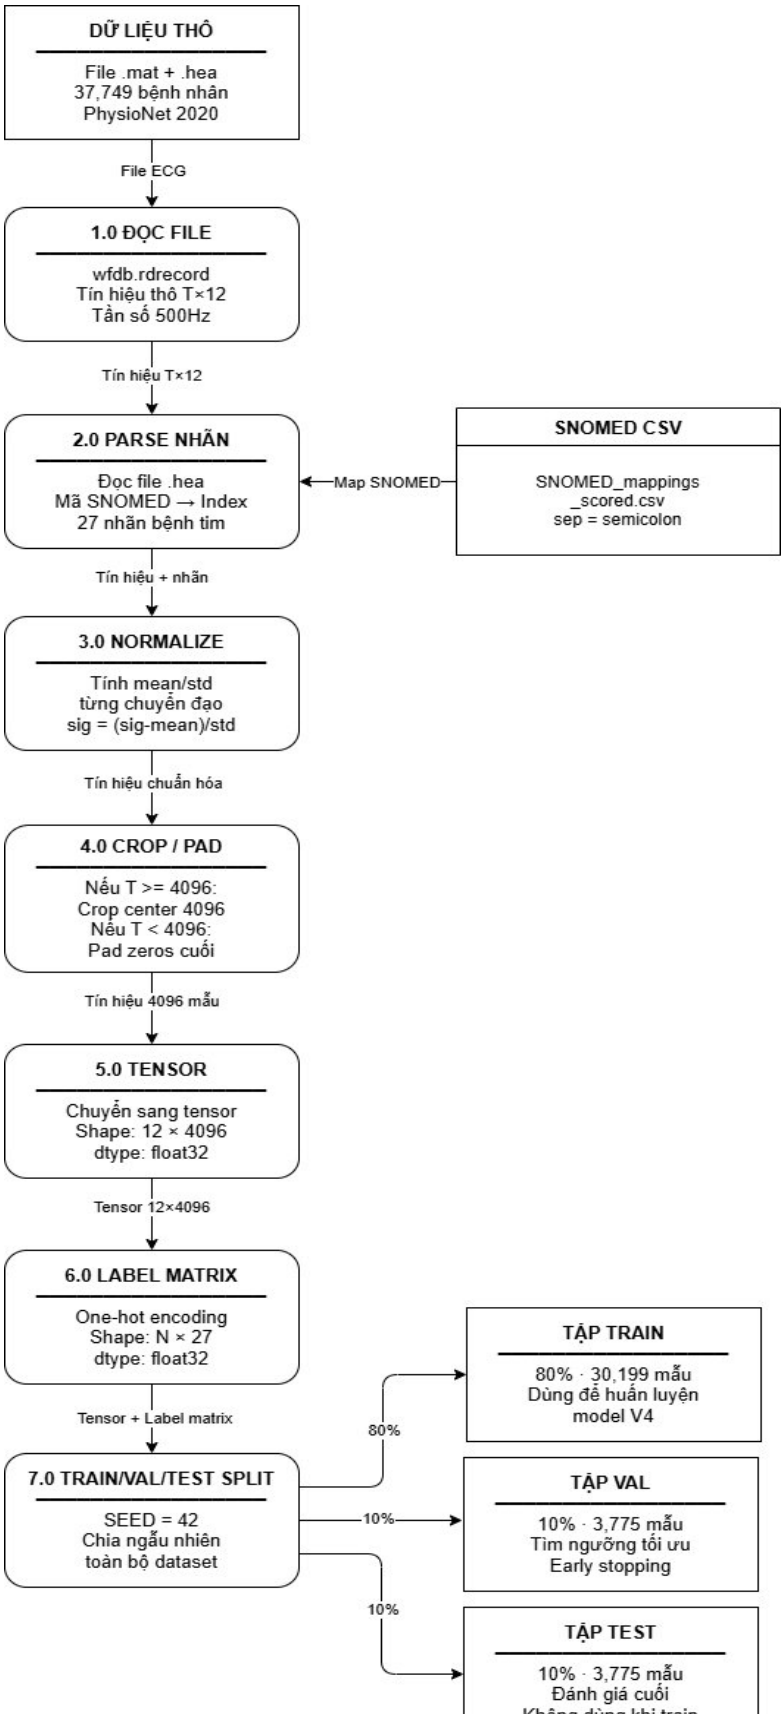

Hình 3. 4. Quy trình Tiền xử lý Dữ liệu ECG và Phân chia Tập Dữ liệu (80/10/10) — PhysioNet Challenge 2020

3.3.2. Sơ đồ hoạt động chức năng tải tín hiệu và dự đoán

Đi sâu vào chức năng cốt lõi nhất của hệ thống, sơ đồ hoạt động (Activity Diagram) mô tả chi tiết các bước chuyển trạng thái khi thực hiện nghiệp vụ tải tín hiệu và dự đoán. Hoạt động bắt đầu tại giao diện người dùng khi bác sĩ nhấn nút tải tệp; hệ thống lập tức chuyển sang trạng thái chờ nạp tệp lên máy chủ. Quá trình xử lý song song được kích hoạt: một nhánh thực hiện việc đọc tệp .mat để trích xuất mảng giá trị biên độ theo thời gian của 12 chuyển đạo, nhánh còn lại đọc tệp .hea để lấy các thông số siêu dữ liệu như tần số lấy mẫu và nhãn cơ sở. Sau khi hai nhánh đồng bộ, mảng dữ liệu hợp nhất được đưa qua hàm tiền xử lý chuẩn hóa z-score và đưa về kích thước 4096 time-steps. Tiếp đó, hoạt động dự đoán khởi chạy module Test-Time Augmentation, thực hiện lặp lại 6 vòng tính toán qua mạng nơ-ron (1 bản gốc và 5 bản thêm nhiễu) để lấy giá trị trung bình. Hoạt động kết thúc khi ma trận xác suất cuối cùng được đối chiếu thành công với ngưỡng thu được từ file JSON và hiển thị lên giao diện.

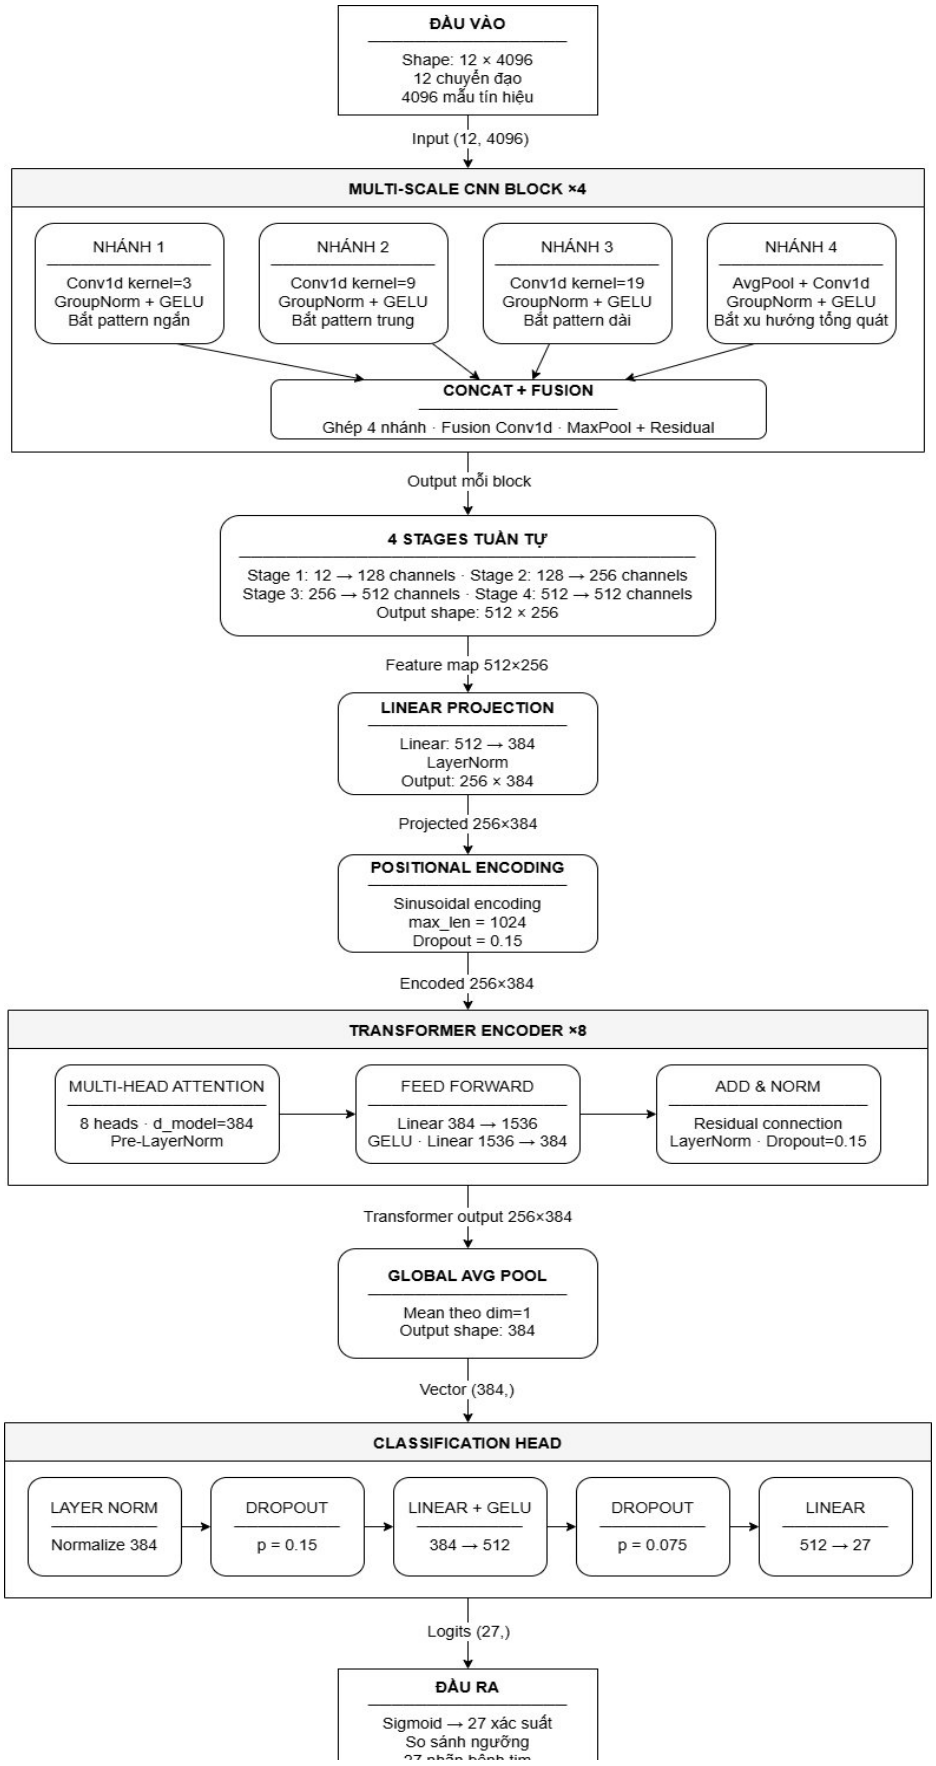

Hình 3. 5. Kiến trúc Mô hình V4: MULTI-SCALE CNN + TRANSFORMER

3.3.3. Sơ đồ tuần tự luồng tiền xử lý và inference

Sơ đồ tuần tự (Sequence Diagram) minh họa trục thời gian và sự tương tác qua lại giữa các đối tượng trong hệ thống cho luồng tiền xử lý và suy luận (inference). Thông điệp đầu tiên xuất phát từ phía Người dùng (Actor) gửi yêu cầu phân tích kèm dữ liệu thô đến Giao diện (Client). Client lập tức gửi gói dữ liệu này đến bộ điều khiển trung tâm (Controller). Tại đây, Controller gọi hàm xử lý từ module Tiền xử lý (Preprocessor) để chuẩn hóa chuỗi thời gian và chờ nhận lại tensor đầu vào. Sau khi nhận được tensor, Controller tiếp tục gửi yêu cầu dự đoán đến module Học sâu (Deep Learning Model), nơi mạng Multi-scale CNN và Transformer thực hiện các phép nhân ma trận cường độ cao trên GPU để trả về vector xác suất. Tiếp theo, Controller chuyển vector này tới module Phân ngưỡng (Thresholding) để ánh xạ sang chẩn đoán nhị phân dựa trên chiến lược F1+Recall. Cuối cùng, kết quả định dạng được gửi ngược về Client để vẽ biểu đồ và hiển thị cho người dùng, khép lại một chu kỳ tương tác hoàn chỉnh.

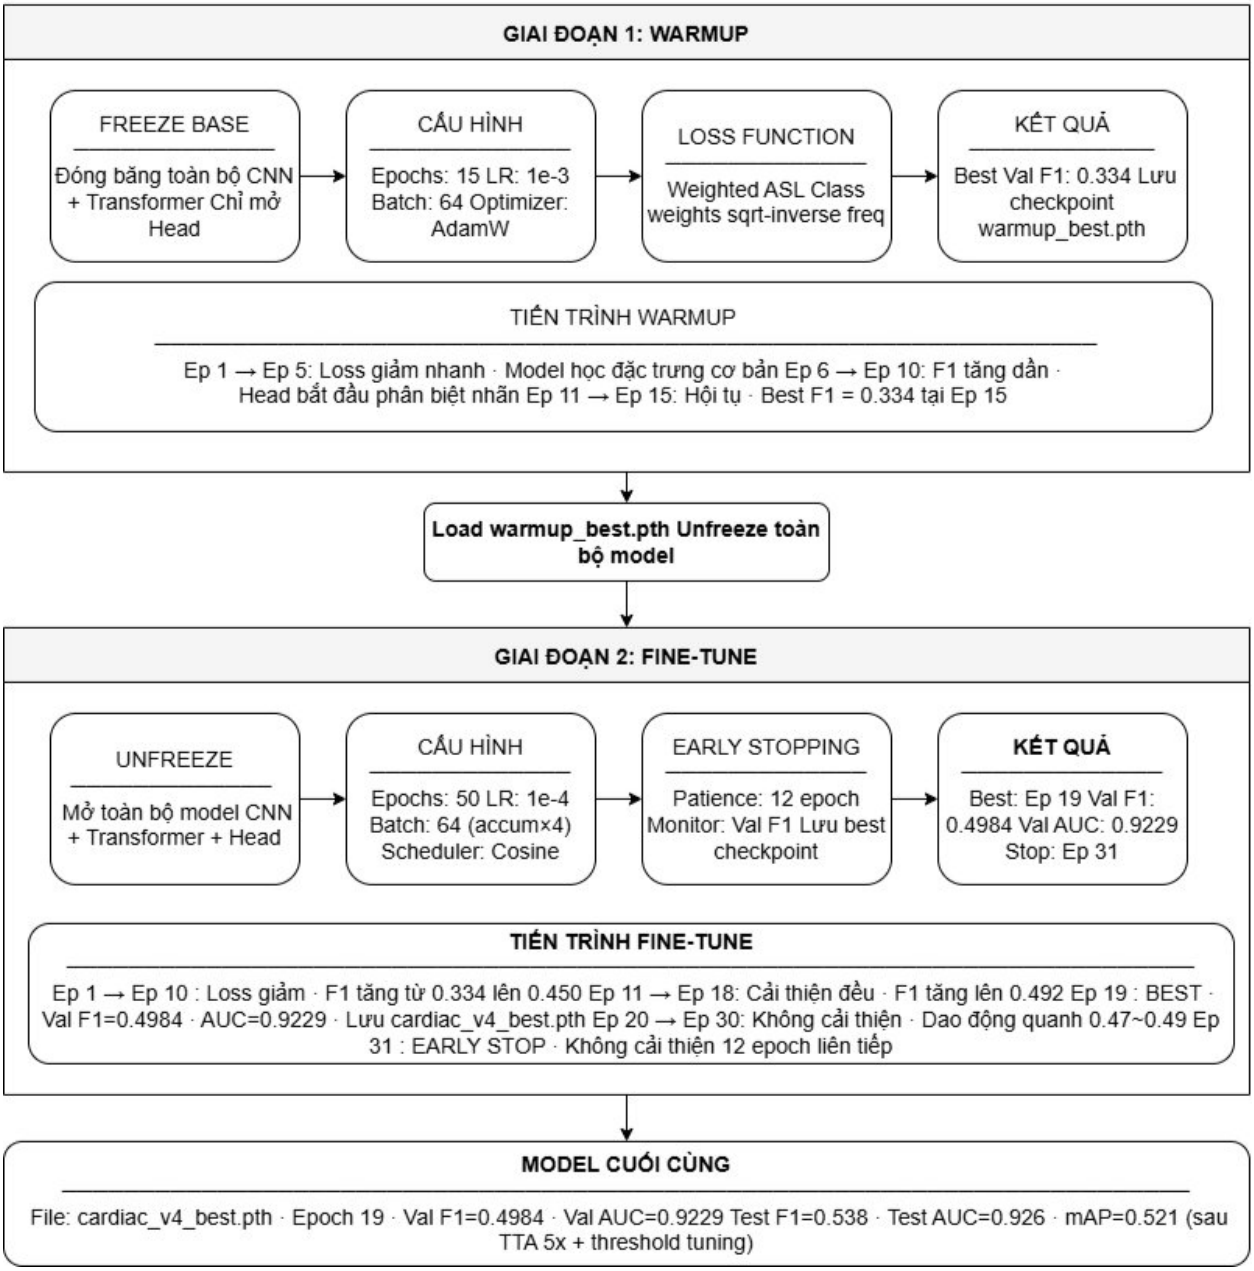

Hình 3. 6. Quy trình huấn luyện 2 Giai đoạn (Warmup → Fine-tune)

3.3.4. Sơ đồ kiến trúc thành phần hệ thống

Để hiện thực hóa các luồng nghiệp vụ trên, sơ đồ kiến trúc thành phần (Component Diagram) thể hiện cách tổ chức mã nguồn và các thư viện tĩnh của hệ thống. Thành phần cốt lõi của phần mềm được xây dựng dựa trên framework PyTorch, đảm nhận toàn bộ quá trình định nghĩa kiến trúc mạng và quản lý biểu đồ tính toán tự động. Module thao tác dữ liệu tích hợp sâu với thư viện WFDB của Python để giải mã các tệp sinh lý học y khoa phức tạp, kết hợp cùng Numpy và Pandas để biến đổi cấu trúc ma trận. Thành phần lưu trữ mô hình bao gồm tệp trọng số đã huấn luyện (cardiac_v4_best.pth) chứa hàng triệu tham số của mạng nơ-ron, đi kèm với thư mục chứa các tệp JSON cấu hình ngưỡng (thr_f1rec_v4.json). Toàn bộ các module logic này được kết nối với nhau thông qua một tệp tin thực thi chính (Inference Script), đóng vai trò điều phối luồng dữ liệu vào ra và giao tiếp với thành phần đồ họa để xuất bản kết quả cuối cùng.

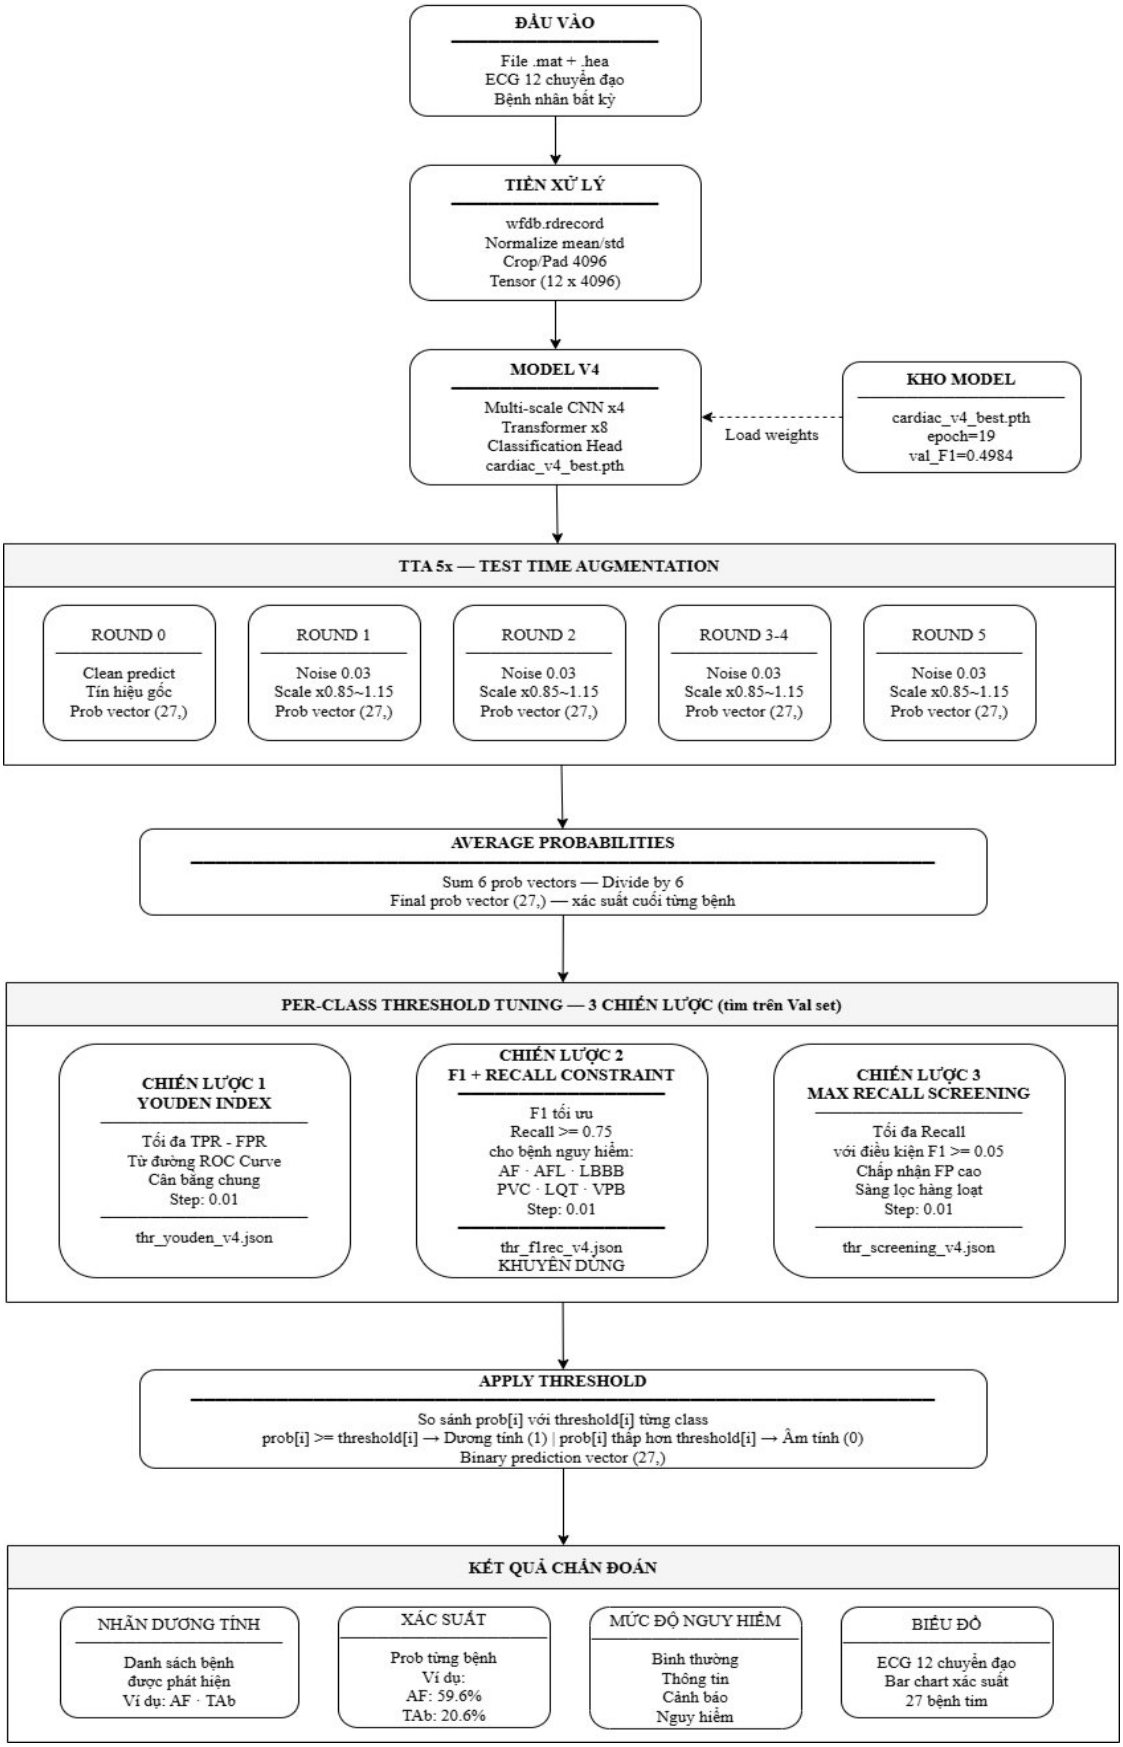

Hình 3. 7. Quy trình Inference và tối ưu ngưỡng phân loại

3.3.5. Sơ đồ triển khai hệ thống

Sơ đồ triển khai (Deployment Diagram) mô tả cấu trúc vật lý của hệ thống khi đưa vào vận hành thực tế. Ở phía máy khách (Client Node), người dùng tương tác với hệ thống thông qua một giao diện tiêu chuẩn chạy trên môi trường máy tính cá nhân hoặc thiết bị y tế tại bệnh viện. Khối xử lý trung tâm (Server Node) không được đặt tại phần cứng cục bộ mà được triển khai hoàn toàn trên hạ tầng điện toán đám mây Kaggle Kernels. Bên trong node máy chủ đám mây này, môi trường thực thi được đóng gói sẵn với Python 3.12, các thư viện học máy chuyên dụng và quan trọng nhất là việc liên kết trực tiếp với thiết bị phần cứng tăng tốc GPU Tesla P100. Việc kiến trúc hệ thống theo mô hình triển khai đám mây giúp giải phóng hoàn toàn gánh nặng tính toán cho các thiết bị y tế cơ sở, cho phép quá trình chẩn đoán phức tạp với mô hình 20 triệu tham số diễn ra nhanh chóng mà không yêu cầu nâng cấp hạ tầng đắt đỏ tại bệnh viện.

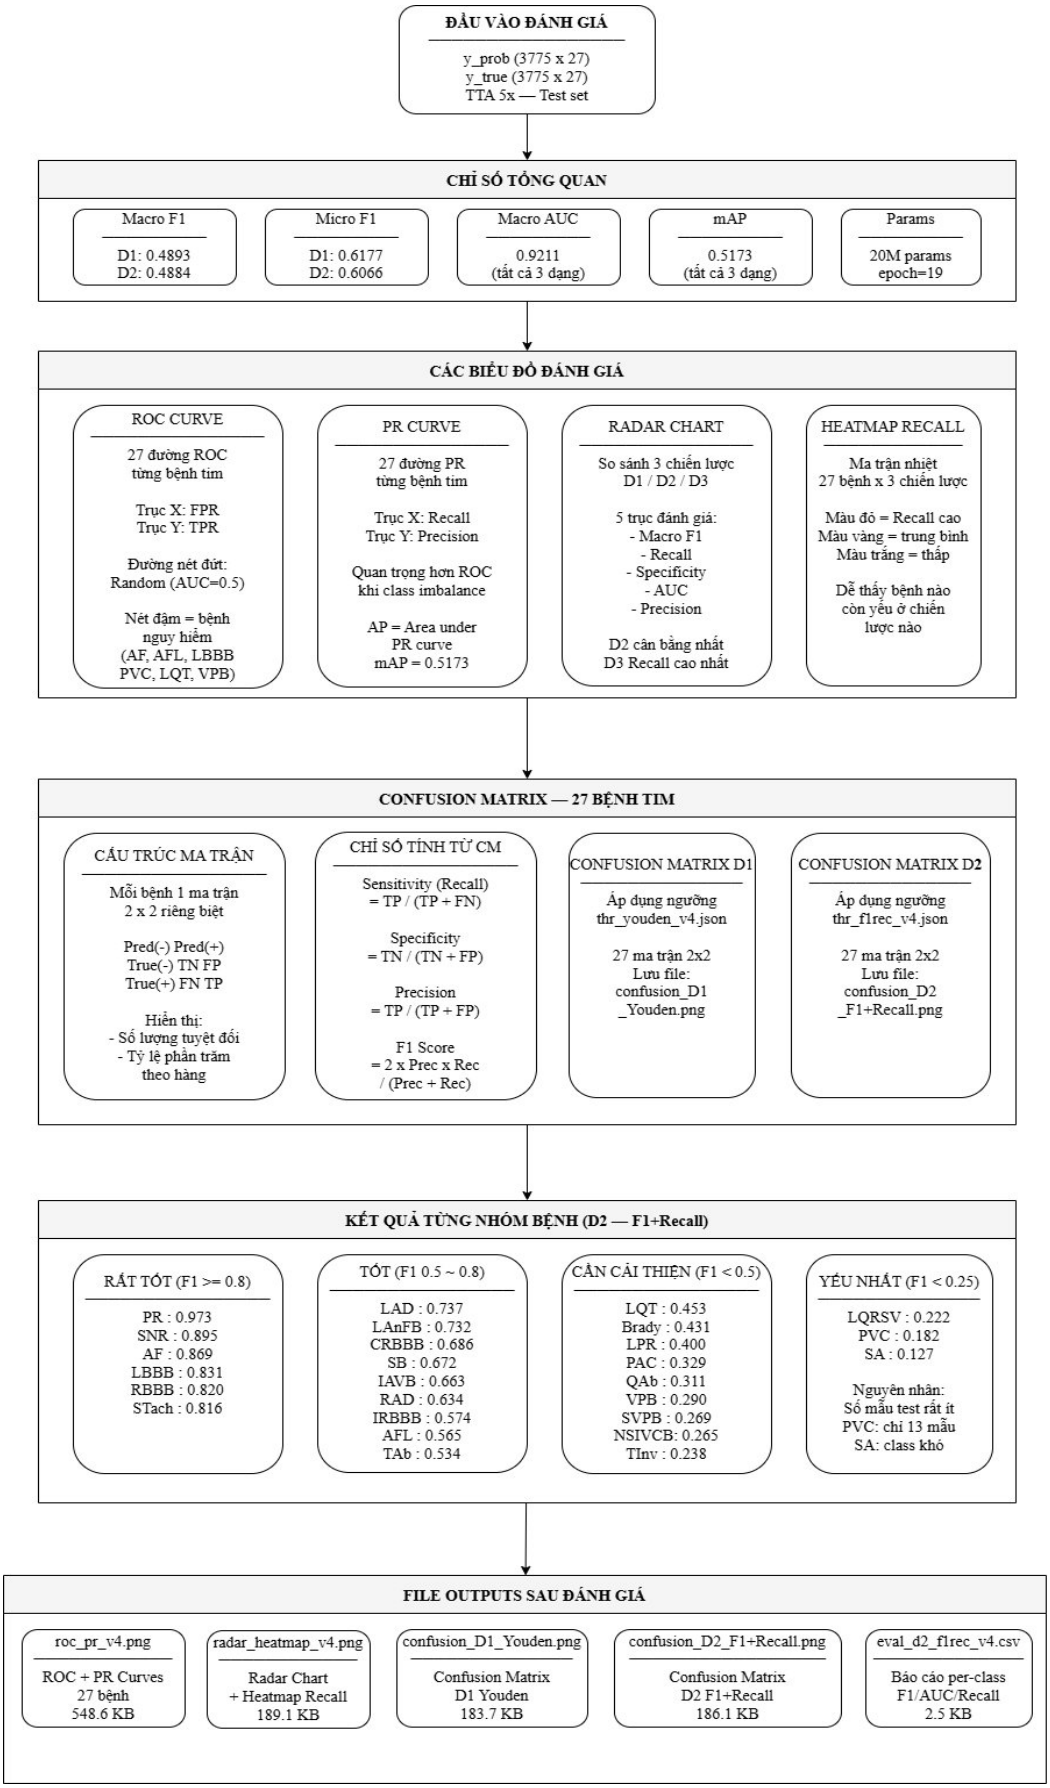

Hình 3. 8. Kết quả đánh giá toàn diện trên tập test

CHƯƠNG 4

XÂY DỰNG MÔ HÌNH CARDIAC AI V4

4.1. Tiền xử lý tín hiệu điện tim

4.1.1. Trích xuất tín hiệu đa kênh và chuẩn hóa

Quá trình tiền xử lý bắt đầu bằng việc trích xuất dữ liệu tín hiệu điện tâm đồ thô từ các tệp tin định dạng WFDB. Sử dụng thư viện chuyên dụng, hệ thống đọc đồng thời tệp .mat chứa ma trận biên độ tín hiệu của 12 chuyển đạo và tệp .hea chứa các thông số kỹ thuật đi kèm. Do mỗi chuyển đạo thu nhận tín hiệu từ một góc độ điện sinh lý khác nhau, biên độ và mức độ dao động cơ sở của chúng có sự chênh lệch đáng kể. Để khắc phục vấn đề này và giúp mô hình học sâu hội tụ nhanh hơn, hệ thống áp dụng kỹ thuật chuẩn hóa phân phối chuẩn (Z-score normalization) độc lập cho từng chuyển đạo.

Quá trình chuẩn hóa được thực hiện dựa trên công thức

$$x_i' = \frac{x_i - \mu}{\sigma}$$

, trong đó x_i là giá trị tín hiệu gốc tại thời điểm i$, $ là giá trị trung bình (mean) của toàn bộ chuỗi tín hiệu trên chuyển đạo đó, và σ là độ lệch chuẩn (standard deviation). Một hằng số epsilon cực nhỏ cũng được cộng thêm vào mẫu số để ngăn chặn lỗi chia cho không đối với các tín hiệu phẳng, đảm bảo tính ổn định tuyệt đối của thuật toán khi triển khai thực tế.

4.1.2. Kỹ thuật đệm/cắt tín hiệu

Sau khi biên độ tín hiệu đã được chuẩn hóa, thách thức tiếp theo là sự không đồng nhất về độ dài thời gian giữa các bản ghi trong bộ dữ liệu PhysioNet Challenge 2020. Mạng nơ-ron học sâu, đặc biệt là các lớp tích chập toàn cục và Transformer, đòi hỏi một kích thước tensor đầu vào cố định định dạng là (12, 4096) tương ứng với 12 kênh và 4096 bước thời gian. Do đó, hệ thống triển khai thuật toán điều chỉnh kích thước động bằng kỹ thuật đệm và cắt tín hiệu (Crop/Pad). Cụ thể, đối với các bản ghi có chiều dài lớn hơn 4096 mẫu, hệ thống tự động tính toán vị trí trung tâm và thực hiện thao tác cắt đối xứng hai đầu (Center Crop) để giữ lại phần thông tin cốt lõi nhất của nhịp tim. Ngược lại, đối với các bản ghi có chiều dài ngắn hơn tiêu chuẩn này, thuật toán áp dụng kỹ thuật đệm giá trị không (Zero Padding) vào phần đuôi của chuỗi tín hiệu để bù đắp khoảng thiếu hụt. Phương pháp này giúp duy trì nguyên vẹn cấu trúc hình thái của các sóng P, QRS, T mà không làm méo mó tín hiệu như các phương pháp co giãn nội suy tuyến tính thông thường.

4.1.3. Tăng cường dữ liệu bằng Gaussian Noise và Amplitude Scaling

Để gia tăng tính mạnh mẽ (robustness) của mô hình và ngăn chặn hiện tượng học vẹt (overfitting) trên tập dữ liệu huấn luyện, hệ thống tích hợp module tăng cường dữ liệu chuỗi thời gian (Data Augmentation). Khác với dữ liệu hình ảnh, tín hiệu y khoa đòi hỏi các kỹ thuật tăng cường phải cực kỳ tinh tế để không làm thay đổi bản chất của bệnh lý. Hệ thống áp dụng hai phương pháp chính gồm chèn nhiễu trắng và nội suy biên độ. Cụ thể, kỹ thuật chèn nhiễu Gaussian với độ lệch chuẩn $\sigma = 0.03$ được cộng trực tiếp vào tín hiệu gốc nhằm giả lập các nhiễu động do điện cực tiếp xúc kém hoặc chuyển động của bệnh nhân trong thực tế. Song song đó, kỹ thuật co giãn biên độ (Amplitude Scaling) thực hiện nhân toàn bộ chuỗi tín hiệu với một hệ số ngẫu nhiên dao động trong khoảng từ 0.85 đến 1.15, giúp mô hình làm quen với các biến thể về điện thế cơ tim ở những thể trạng bệnh nhân khác nhau. Các kỹ thuật này không chỉ áp dụng trong pha huấn luyện mà còn được tái sử dụng trong pha suy luận thông qua phương pháp Test-Time Augmentation (TTA 5x) nhằm củng cố độ tin cậy của kết quả dự đoán.

4.1.4. Phân chia tập dữ liệu huấn luyện và kiểm thử

Sau khi hoàn tất các bước tiền xử lý và chuẩn hóa tín hiệu, toàn bộ 37.749 bản ghi ECG hợp lệ được tiến hành phân chia thành ba tập dữ liệu hoàn toàn độc lập nhằm phục vụ cho vòng đời phát triển của mô hình học sâu. Quá trình phân chia được thực hiện ngẫu nhiên với hạt giống cố định (random seed) nhằm đảm bảo tính tái lập (reproducibility) của thực nghiệm, đồng thời duy trì tỷ lệ phân bố nhãn bệnh lý đồng đều giữa các tập. Cụ thể, 80% dữ liệu (tương đương 30.199 bản ghi) được phân bổ cho tập huấn luyện (Training set) để mô hình học các trọng số và trích xuất đặc trưng y khoa; 10% dữ liệu (tương đương 3.775 bản ghi) được sử dụng cho tập kiểm định (Validation set) nhằm giám sát quá trình học, tìm kiếm bộ ngưỡng chẩn đoán tối ưu và áp dụng thuật toán dừng sớm (Early Stopping) để ngăn chặn hiện tượng quá khớp (Overfitting). Khối lượng 10% dữ liệu còn lại (3.775 bản ghi) được giữ hoàn toàn tách biệt đối với quá trình huấn luyện và chỉ được sử dụng làm tập kiểm thử (Test set) độc lập để đo lường hiệu năng tổng quát cuối cùng (chi tiết tỷ lệ được thể hiện tại Bảng 3.1). Việc phân lập dữ liệu rõ ràng và nghiêm ngặt này tuân thủ các tiêu chuẩn đánh giá khắt khe trong nghiên cứu y tế, đảm bảo mọi chỉ số hiệu năng đầu ra của hệ thống đều phản ánh trung thực khả năng chẩn đoán trong điều kiện thực tế.

Bảng 4. 1. Phân chia tập dữ liệu huấn luyện, kiểm định và kiểm thử

Tập dữ liệu (Dataset)	Tỷ lệ phân chia	Số lượng bản ghi (Mẫu)	Mục đích sử dụng
Huấn luyện (Train)	80%	30.199	Huấn luyện trọng số mô hình, trích xuất đặc trưng
Kiểm định (Validation)	10%	3.775	Đánh giá epoch, tìm ngưỡng tối ưu, Early Stopping
Kiểm thử (Test)	10%	3.775	Đánh giá hiệu năng tổng quát cuối cùng độc lập
Tổng cộng	100%	37.749	

4.2. Đề xuất kiến trúc mạng kết hợp CNN và Transformer

4.2.1. Thiết kế khối MultiScaleConvBlock với 4 nhánh trích xuất đặc trưng

Trái tim của kiến trúc trích xuất đặc trưng cục bộ trong hệ thống Cardiac AI V4 nằm ở thiết kế khối tích chập đa tỷ lệ (MultiScaleConvBlock). Đối với tín hiệu chuỗi thời gian một chiều như điện tâm đồ, các dấu hiệu bệnh lý thường xuất hiện dưới những dải tần số và khoảng thời gian rất khác nhau; điển hình như phức bộ QRS diễn ra vô cùng chớp nhoáng, trong khi các bất thường ở đoạn ST hoặc sóng T lại kéo dài hơn đáng kể. Để giải quyết thách thức này, khối MultiScaleConvBlock được thiết kế với cơ chế hoạt động song song, phân nhánh tín hiệu đầu vào có kích thước ma trận $(B,12,4096)$ thành bốn luồng xử lý độc lập. Việc từ bỏ cấu trúc tích chập tuyến tính nối tiếp truyền thống để chuyển sang mạng phân nhánh đa tỷ lệ giúp mô hình bao quát toàn diện mọi biến thiên của chuỗi tín hiệu, từ những vi động điện thế nhỏ nhất cho đến các xu hướng nhịp tim kéo dài, tạo ra một không gian biểu diễn đặc trưng vô cùng phong phú trước khi đưa vào các tầng chú ý sâu hơn.

Kiến trúc bên trong của khối được cấu thành từ ba nhánh tích chập một chiều (1D CNN) với kích thước bộ lọc (kernel size) lần lượt là 3, 9 và 19, kết hợp cùng một nhánh thứ tư sử dụng hàm gộp trung bình (Average Pooling). Nhánh thứ nhất với bộ

lọc hạt nhân kích thước 3 đóng vai trò như một lăng kính vi mô, chuyên biệt trong việc bắt giữ các biến thiên tần số cao và sắc nét. Nhánh thứ hai sử dụng bộ lọc kích thước 9 để trích xuất các hình thái tầm trung, trong khi nhánh thứ ba với kích thước hạt nhân lên tới 19 chịu trách nhiệm phân tích các sóng chậm mang tần số thấp. Đặc biệt, nhánh thứ tư áp dụng phép gộp trung bình theo thời gian, sau đó đi qua một lớp tích chập hạt nhân kích thước 1 nhằm nắm bắt ngữ cảnh nền và triệt tiêu các nhiễu động cục bộ. Kết quả đầu ra từ bốn nhánh song song này sau đó được ghép nối trực tiếp với nhau (concatenate) dọc theo chiều không gian của các kênh (channel dimension) để tạo thành một tensor thống nhất.

Sau bước ghép nối đặc trưng từ bốn nhánh, khối lượng thông tin không gian thu được là rất đồ sộ. Do đó, hệ thống tiếp tục áp dụng một lớp tích chập điểm (pointwise convolution) với kích thước hạt nhân bằng 1 nhằm hòa trộn thông tin chéo giữa các kênh, đồng thời nén và kiểm soát chặt chẽ số lượng chiều đặc trưng đầu ra. Chuỗi dữ liệu này ngay lập tức đi qua các lớp chuẩn hóa theo lô (Batch Normalization) để ổn định gradient trong quá trình huấn luyện và hàm kích hoạt phi tuyến tính nhằm tăng cường khả năng biểu diễn các hàm toán học phức tạp. Trong tổng thể kiến trúc phần đầu của Cardiac AI V4, các khối MultiScaleConvBlock này được xếp chồng lên nhau thành các tầng liên tiếp với cơ chế gộp (pooling) xen kẽ. Thiết kế này giúp số lượng kênh đặc trưng tăng dần theo tiến trình $128 \rightarrow \rightarrow 256 \rightarrow \rightarrow 512$, trong khi chiều dài chuỗi thời gian giảm dần, tạo ra một bộ nén thông tin cục bộ hoàn hảo trước khi chuyển giao toàn bộ ma trận này cho khối Transformer Encoder ở giai đoạn tiếp theo.

.4.2.2. Thiết kế khối Transformer Encoder với cơ chế Self-Attention

Mặc dù khối Multi-scale CNN ở giai đoạn trước đã hoàn thành xuất sắc nhiệm vụ trích xuất các đặc trưng hình thái cục bộ (như phức bộ QRS hay sóng P, sóng T), hạn chế cố hữu của mạng tích chập là trường nhìn (receptive field) bị giới hạn. Đối với chẩn đoán điện tâm đồ, nhiều bệnh lý như rối loạn nhịp tim (Arrhythmia) hay rung nhĩ (Atrial Fibrillation) đòi hỏi hệ thống phải nắm bắt được khoảng cách và mối tương quan giữa các nhịp đập cách xa nhau trên toàn bộ chuỗi thời gian dài. Để khắc phục điểm yếu này, hệ thống Cardiac AI V4 tích hợp thêm một khối Transformer Encoder ngay sau các tầng CNN nhằm khai thác tối đa khả năng học các phụ thuộc xa (long-range dependencies) thông qua cơ chế tự chú ý (Self-Attention). Trước khi tensor đặc trưng đi vào Transformer, do bản chất của mạng chú ý không có khái niệm về thứ tự không gian hay thời gian, hệ thống sẽ cộng thêm một ma trận mã hóa vị trí (Positional Encoding) vào dữ liệu để giữ lại thông tin về trật tự trước sau của chuỗi tín hiệu nhịp tim.

Cốt lõi sức mạnh của khối Transformer Encoder trong dự án nằm ở cơ chế Multi-Head Self-Attention (MHSA). Thay vì chỉ tập trung vào một khía cạnh duy nhất, tín hiệu đầu vào với chiều không gian đặc trưng $d_{model} = 384$ sẽ được phóng chiếu tuyến tính thành ba ma trận Query (Q), Key (K) và Value (V). Hệ thống thiết lập cơ chế chú ý đa đầu với 8 heads hoạt động song song. Mỗi head sẽ học cách tính toán mức độ "chú ý" (attention score) giữa một điểm thời gian cụ thể với tất cả các điểm thời gian khác trong chuỗi tín hiệu, dựa trên phép nhân ma trận giữa Q và K, sau đó chuẩn hóa bằng hàm Softmax và nhân với V. Việc sử dụng 8 heads cho phép mô hình đồng thời quan sát chuỗi ECG dưới nhiều góc độ bệnh lý khác nhau; ví dụ: một head có thể chuyên theo dõi khoảng R-R để tìm dấu hiệu nhịp không đều, trong khi một head khác lại tập trung vào sự chênh lên của đoạn ST. Kết quả từ 8 heads này sau đó được nối lại (concatenate) và đưa qua một màng lọc tuyến tính để khôi phục lại kích thước chiều ban đầu.

Để tăng cường khả năng biểu diễn phi tuyến và độ sâu của mô hình, khối Transformer Encoder của Cardiac AI V4 được thiết kế xếp chồng lên nhau với tổng cộng 8 lớp (8 Layers) liên tiếp. Bên trong mỗi lớp, ngoài module MHSA, tensor dữ liệu còn đi qua một mạng nơ-ron truyền thẳng (Feed-Forward Network) bao gồm hai lớp tuyến tính đan xen với hàm kích hoạt GELU. Nhằm đảm bảo quá trình huấn luyện diễn ra ổn định và ngăn chặn hiện tượng triệt tiêu đạo hàm (vanishing gradient) khi mô hình trở nên quá sâu, kiến trúc sử dụng các kết nối thặng dư (Residual Connections) bỏ qua các lớp kết hợp với kỹ thuật chuẩn hóa tầng (Layer Normalization) được đặt ngay trước các module chính. Sự kết hợp tinh tế giữa 8 lớp Transformer Encoder và khối trích xuất cục bộ Multi-scale CNN đã tạo ra một bộ máy nhận thức toàn diện, vừa có khả năng phân tích chi tiết từng sóng đơn lẻ, vừa có tầm nhìn bao quát toàn bộ chuỗi nhịp đập, từ đó nâng cao đáng kể độ chính xác trong việc phân loại 27 nhãn bệnh lý tim mạch phức tạp.

4.2.3. Xây dựng Classification Head cho phân loại đa nhãn

Sau khi chuỗi tín hiệu đi qua 8 lớp của khối Transformer Encoder, tensor đầu ra mang theo một lượng lớn các đặc trưng biểu diễn toàn cục và cục bộ, nhưng vẫn duy trì cấu trúc không gian ba chiều bao gồm kích thước lô (batch size), chiều dài chuỗi thời gian và số chiều đặc trưng $(d_{model} = 384)$ Để chuyển đổi khối dữ liệu khổng lồ này thành các dự đoán y khoa cụ thể, hệ thống trước tiên áp dụng lớp gộp trung bình toàn cục (Global Average Pooling - GAP). Thao tác này thực hiện việc tính trung bình cộng dọc theo toàn bộ trục thời gian, nén tensor từ không gian ba chiều xuống còn hai chiều. Lớp GAP không chỉ giúp giảm thiểu đáng kể số lượng tham số cần tính toán ở các bước tiếp theo mà còn đóng vai trò quan trọng trong việc ngăn chặn hiện tượng quá khớp (overfitting), đồng thời tổng hợp lại những dấu hiệu bệnh lý quan trọng nhất bất kể chúng xuất hiện ở thời điểm nào trong bản ghi điện tâm đồ.

Tensor sau khi được làm phẳng sẽ được đưa qua một mạng kết nối đầy đủ (Fully Connected Layer) hay còn gọi là lớp tuyến tính (Linear Layer). Lớp này thực hiện một phép nhân ma trận để ánh xạ không gian đặc trưng từ 384 chiều xuống chính xác 27 chiều, tương ứng với 27 nhãn bệnh lý tim mạch mục tiêu của bộ dữ liệu PhysioNet Challenge 2020. Đầu ra của lớp tuyến tính này là các giá trị logit thô (raw logits), có thể mang giá trị âm hoặc dương bất kỳ và chưa thể hiện được xác suất. Đối với các bài toán phân loại đa lớp (multi-class) thông thường, hàm Softmax thường được sử dụng để ép tổng xác suất của tất cả các lớp bằng 1. Tuy nhiên, chẩn đoán điện tâm đồ trong thực tế là một bài toán phân loại đa nhãn (multi-label classification), nơi một bệnh nhân hoàn toàn có thể đồng thời mắc nhiều bệnh lý khác nhau (ví dụ: vừa bị rung nhĩ, vừa bị block nhánh phải).

Để giải quyết bản chất đa nhãn này, hệ thống Cardiac AI V4 thiết kế Classification Head sử dụng hàm kích hoạt Sigmoid độc lập cho từng node đầu ra. Hàm Sigmoid có nhiệm vụ nén từng giá trị logit thô z_i vào khoảng giới hạn từ 0 đến 1, đại diện cho xác suất độc lập của từng nhãn bệnh lý i (với i chạy từ 1 đến 27). Công thức toán học của hàm Sigmoid được biểu diễn như sau:

$$\sigma(z_i) = \frac{1}{1 + e^{-z_i}}$$

Trong đó:

s (z_i) là xác suất dự đoán cho bệnh lý thứ i (nhận giá trị từ 0 đến 1).

z_i là giá trị logit đầu ra từ lớp tuyến tính cho bệnh lý thứ i.

e là cơ số của logarit tự nhiên (khoảng 2.71828).

Việc áp dụng hàm Sigmoid đảm bảo rằng sự hiện diện (xác suất cao) của một bệnh lý này sẽ không làm suy giảm xác suất của các bệnh lý khác. Mảng 27 giá trị xác suất thu được từ hàm kích hoạt này chính là kết quả suy luận cuối cùng của mô hình học sâu, đóng vai trò là dữ liệu đầu vào cho khối phân ngưỡng y tế (Thresholding) để đưa ra các kết luận nhị phân cuối cùng trên giao diện hệ thống.

4.3. Thiết lập tham số và tiến trình huấn luyện

4.3.1. Cấu hình siêu tham số (Hyperparameters) và Kỹ thuật Gradient Accumulation

Để mô hình kết hợp giữa Multi-scale CNN và Transformer Encoder có thể hội tụ hiệu quả và đạt được trọng số tối ưu, việc thiết lập bộ siêu tham số (hyperparameters) đóng vai trò quyết định trong suốt quá trình huấn luyện. Hệ thống Cardiac AI V4 sử dụng thuật toán tối ưu hóa AdamW (Adam with Weight Decay), một biến thể cải tiến của bộ tối ưu Adam truyền thống, giúp khắc phục hiệu quả hiện

tượng suy giảm trọng số (weight decay) trong các mạng học sâu có kiến trúc Transformer. Tốc độ học khởi tạo (learning rate) được thiết lập ở mức 1×10^{-4} kết hợp với lịch trình làm ấm (warm-up) trong các epoch đầu tiên để tránh hiện tượng sốc gradient, sau đó giảm dần theo chiến lược Cosine Annealing. Bên cạnh đó, số lượng kỷ nguyên huấn luyện (epochs) được cấu hình là 50, đi kèm với thuật toán dừng sớm (Early Stopping). Thuật toán này sẽ liên tục giám sát chỉ số Macro F1 trên tập kiểm định (Validation set); nếu hiệu năng không được cải thiện sau 7 epoch liên tiếp, quá trình huấn luyện sẽ tự động chấm dứt nhằm tiết kiệm tài nguyên và ngăn chặn mô hình học vẹt (overfitting) các nhiễu cục bộ của tập dữ liệu..

Một trong những thách thức lớn nhất khi huấn luyện kiến trúc Cardiac AI V4 là giới hạn về bộ nhớ vật lý (VRAM) của phần cứng. Với việc mỗi bản ghi điện tim mang kích thước $(12, 4096)$ đi qua mạng CNN 4 nhánh và khối Transformer 8 lớp với $d_{model} = 384$, không gian bộ nhớ tính toán phình lên rất nhanh. Khi triển khai trên môi trường máy chủ đám mây với GPU Tesla P100 (dung lượng 16GB VRAM), hệ thống không thể đáp ứng được kích thước lô (batch size) lớn lý tưởng như 64 hay 128 mẫu cùng lúc, mà chỉ giới hạn ở mức tối đa là 16 mẫu cho mỗi vòng lặp tiến (forward pass). Tuy nhiên, một kích thước lô quá nhỏ sẽ dẫn đến việc ước lượng gradient bị nhiễu, làm quỹ đạo cập nhật trọng số trở nên mất ổn định và khiến mô hình khó hội tụ tới điểm cực tiểu toàn cục.

Để giải quyết bài toán nút thắt cổ chai về phần cứng này mà không làm suy giảm hiệu năng toán học, hệ thống áp dụng kỹ thuật tích lũy đạo hàm (Gradient Accumulation). Thay vì cập nhật trọng số ngay lập tức sau mỗi lô nhỏ 16 mẫu, kỹ thuật này sẽ tính toán bước tiến và bước lùi (backward pass) để tìm ra đạo hàm, nhưng lưu trữ và cộng dồn các giá trị đạo hàm này lại trong bộ nhớ qua nhiều bước (accumulation steps). Cụ thể, hệ thống được thiết lập số bước tích lũy là 4. Như vậy, đạo hàm của 4 lô nhỏ liên tiếp sẽ được cộng dồn lại theo công thức:

$$\nabla L_{total} = \sum_{i=1}^{4} \nabla L_i$$

Chỉ khi quá trình cộng dồn hoàn tất (tương dương với việc đã duyệt qua 16 x 4 = 64 bản ghi), hàm optimizer.step() mới được gọi để cập nhật hệ số của mạng nơ-ron một lần duy nhất, sau đó bộ nhớ gradient sẽ được xóa trắng (optimizer.zero_grad()) để bắt đầu chu kỳ mới. Kỹ thuật này giúp hệ thống mô phỏng hoàn hảo một batch size lớn là 64 mang lại sự ổn định tuyệt đối cho quỹ đạo hội tụ, đồng thời vẫn tuân thủ nghiêm ngặt giới hạn 16GB VRAM của thiết bị phần cứng thực tế.

4.3.2. Lịch trình học Cosine (Cosine Annealing LR)

Trong quá trình tối ưu hóa các mạng nơ-ron sâu có kiến trúc phức tạp như sự kết hợp giữa Multi-scale CNN và Transformer, việc duy trì một tốc độ học (learning rate) cố định xuyên suốt các kỷ nguyên (epochs) thường dẫn đến hiện tượng mô hình hội tụ chậm hoặc dao động mạnh quanh vùng cực tiểu toàn cục. Ở những pha đầu của quá trình huấn luyện, mạng học sâu cần một bước nhảy gradient đủ lớn để nhanh chóng thoát khỏi các điểm cực tiểu địa phương (local minima) và khám phá không gian trọng số một cách toàn diện. Tuy nhiên, khi mô hình đã tiến gần đến điểm hội tụ tối ưu, một tốc độ học lớn sẽ khiến quỹ đạo cập nhật bị trượt qua (overshoot) điểm đích đích thực, làm suy giảm độ chính xác tổng thể. Để giải quyết triệt để bài toán này, hệ thống Cardiac AI V4 tích hợp lịch trình điều chỉnh tốc độ học Cosine (Cosine Annealing Learning Rate), một kỹ thuật tinh chỉnh siêu tham số động mang lại hiệu năng vượt trội trong các bài toán học máy.

Thuật toán Cosine Annealing thực hiện việc suy giảm tốc độ học η_t tại mỗi thời điểm t tuân theo hình dáng của nửa chu kỳ hàm lượng giác Cosine. Quá trình này bắt đầu từ một giá trị tốc độ học tối đa được cấu hình ban đầu (η_{max})và giảm dần một cách mượt mà xuống mức tối thiểu (η_{min}) khi tiến gần đến kỷ nguyên huấn luyện cuối cùng (T_{max}) . Công thức toán học cốt lõi điều khiển sự suy giảm này được biểu diễn như sau:

$$\eta_t = \eta_{min} + \frac{1}{2}(\eta_{max} - \eta_{min})\left(1 + \cos\left(\frac{T_{cur}}{T_{max}}\pi\right)\right)$$

Trong đó, T_{cur} đại diện cho số kỷ nguyên (hoặc số bước lặp) hiện tại mà mô hình đã trải qua. Điểm ưu việt của đường cong suy giảm Cosine so với các phương pháp giảm bậc thang (Step Decay) thông thường nằm ở tốc độ thay đổi phi tuyến: ở những epoch đầu tiên, tốc độ học giảm rất chậm, cho phép mô hình duy trì đà khám phá không gian đặc trưng một cách rộng rãi; ở giai đoạn giữa, tốc độ học trượt xuống một cách nhanh chóng để đưa mô hình đi sâu vào vùng cực tiểu; và ở những epoch cuối cùng, đường cong lại thoải dần, cho phép hệ thống thực hiện các tinh chỉnh vi mô (fine-tuning) thận trọng nhất trên từng tham số. Sự kết hợp nhịp nhàng giữa thuật toán tối ưu AdamW, kỹ thuật Gradient Accumulation và lịch trình Cosine Annealing đã tạo ra một bệ phóng hoàn hảo, giúp kiến trúc Cardiac AI V4 chắt lọc được những biểu diễn toán học tinh tế nhất để chẩn đoán chính xác 27 nhãn bệnh lý phức tạp.

4.3.3. Tiến trình Warmup và Fine-tuning toàn mô hình

Kỹ thuật làm ấm (Warmup) được áp dụng trong giai đoạn khởi đầu của quá trình huấn luyện nhằm duy trì tính ổn định của các bản cập nhật gradient. Khi mô hình

phức tạp như Cardiac AI V4 vừa được khởi tạo, các tham số trọng số của khối Multi-scale CNN và khối Transformer vẫn hoàn toàn nằm ở trạng thái ngẫu nhiên. Nếu hệ thống áp dụng ngay lập tức một tốc độ học (learning rate) lớn, sự chênh lệch đột ngột trong các tính toán sai số có thể dẫn đến hiện tượng bùng nổ đạo hàm (exploding gradients), khiến quỹ đạo hội tụ bị phá vỡ và các giá trị hàm mất mát biến thành vô cực (NaN). Để khắc phục rủi ro này, hệ thống thiết lập một tiến trình làm ấm tuyến tính (Linear Warmup) kéo dài trong các kỷ nguyên đầu tiên. Trong pha này, tốc độ học sẽ tăng dần đều từ một giá trị tiệm cận 0 cho đến khi đạt được mức tốc độ học cơ sở (h_{max}) đã được cấu hình. Kỹ thuật Warmup đóng vai trò như một bước đệm an toàn, cho phép mạng nơ-ron từ từ thích nghi với phân phối hình thái của 27 nhãn bệnh lý điện tâm đồ trước khi bước vào giai đoạn tăng tốc và suy giảm bằng thuật toán Cosine Annealing.

Ngay sau khi kết thúc pha làm ấm, hệ thống kích hoạt chiến lược tinh chỉnh toàn bộ kiến trúc từ đầu đến cuối (End-to-End Fine-tuning). Thay vì đóng băng (freeze) các trọng số và huấn luyện riêng lẻ từng phần (chẳng hạn như huấn luyện trước khối CNN rồi mới ghép vào Transformer), chiến lược tinh chỉnh toàn mô hình cho phép luồng gradient lan truyền ngược (backpropagation) xuyên suốt từ lớp phân loại cuối cùng (Classification Head) qua các tầng Self-Attention và đi sâu xuống tận cùng các nhánh tích chập đa tỷ lệ. Việc huấn luyện đồng thời này mang lại một lợi thế toán học to lớn: khối CNN không chỉ trích xuất các đặc trưng hình thái cục bộ một cách độc lập, mà còn liên tục tự động điều chỉnh các bộ lọc hạt nhân sao cho kết quả tensor đầu ra phù hợp và tối ưu nhất với cơ chế tính toán ma trận Query-Key-Value của khối Transformer phía sau. Sự tối ưu hóa liên hoàn này giúp xóa bỏ mọi "nút thắt cổ chai" về thông tin giữa hai luồng kiến trúc mạng bản chất khác biệt, đẩy lùi sai số tổng thể và tối đa hóa khả năng chẩn đoán chính xác của toàn hệ thống trong suốt toàn bộ chu kỳ huấn luyện.

CHƯƠNG 5
KẾT QUẢ THỰC NGHIỆM VÀ ĐÁNH GIÁ

5.1 Môi trường thực nghiệm và độ đo đánh giá

5.1.1. Cấu hình môi trường thực nghiệm

Để đảm bảo tính khả thi trong việc huấn luyện một kiến trúc học sâu phức tạp bao gồm hàng chục triệu tham số từ mạng Multi-scale CNN và Transformer, toàn bộ quá trình thực nghiệm của đồ án được triển khai trên nền tảng điện toán đám mây thay vì sử dụng phần cứng cục bộ. Máy chủ thực thi được cấp phát là hệ thống máy ảo với bộ vi xử lý Intel Xeon, dung lượng RAM hệ thống 30GB và đặc biệt là bộ xử lý đồ họa chuyên dụng GPU NVIDIA Tesla P100 được trang bị 16GB VRAM. Môi trường phần mềm được xây dựng trên nền tảng ngôn ngữ lập trình Python phiên bản 3.12, kết hợp với framework học sâu mã nguồn mở PyTorch để định nghĩa biểu đồ tính toán động và tối ưu hóa quá trình lan truyền ngược trên GPU. Bên cạnh đó, các thư viện hỗ trợ chuyên dụng như WFDB được sử dụng để đọc tệp sinh lý học y khoa, Numpy và Pandas phục vụ xử lý ma trận số liệu, cùng với Matplotlib và Seaborn để trực quan hóa biểu đồ đánh giá ở các bước hậu xử lý. Việc đồng bộ hóa môi trường này giúp các kết quả thực nghiệm đạt được tính ổn định, dễ dàng tái lập và tối ưu hóa tối đa thời gian huấn luyện mô hình.

5.1.2. Các độ đo đánh giá hiệu năng

Do bài toán chẩn đoán điện tâm đồ 12 chuyển đạo trong phạm vi đồ án là một bài toán phân loại đa nhãn (multi-label classification) với 27 nhãn bệnh lý mang tính chất mất cân bằng dữ liệu nghiêm trọng, hệ thống không sử dụng độ chính xác tổng thể (Accuracy) làm thước đo chính. Thay vào đó, mô hình được đánh giá toàn diện dựa trên ba chỉ số cốt lõi: Macro F1-score, Area Under the ROC Curve (AUC) và Mean Average Precision (mAP).

Để tính toán F1-score, hệ thống dựa trên ma trận nhầm lẫn (Confusion Matrix) của từng nhãn bệnh lý độc lập, bao gồm các giá trị: True Positive (TP), False Positive (FP), True Negative (TN) và False Negative (FN). Từ đó, hai chỉ số thành phần là độ phân giải (Precision) và độ nhạy (Recall) được định nghĩa theo công thức:

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

Chỉ số F1 là trung bình điều hòa của Precision và Recall, giúp cân bằng giữa việc dự đoán đúng bệnh và không bỏ sót bệnh nhân:

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Nhằm đảm bảo sự công bằng cho các căn bệnh hiếm gặp (có ít mẫu dữ liệu), đồ án áp dụng chiến lược trung bình vĩ mô (Macro-averaging). Theo đó, chỉ số F1 được tính toán độc lập cho từng nhãn trong số 27 bệnh lý, sau đó lấy trung bình cộng của tất cả 27 giá trị này để ra được Macro F1 cuối cùng. Bên cạnh Macro F1, chỉ số AUC được sử dụng để đo lường khả năng phân tách đường cong đặc trưng hoạt động (ROC) của mô hình bất chấp sự thay đổi của các ngưỡng xác suất. Cuối cùng, chỉ số mAP cung cấp thêm một góc nhìn đánh giá trung bình diện tích dưới đường cong Precision-Recall, đặc biệt nhạy bén với các bài toán có sự chênh lệch lớn giữa lớp âm tính và dương tính trong môi trường y khoa.

5.2. Chiến lược tối ưu ngưỡng phân loại (Thresholding)

5.2.1. Chiến lược 1: Dựa trên chỉ số Youden (Youden Index)

Trong bài toán phân loại đa nhãn với bộ dữ liệu y tế có sự mất cân bằng nghiêm trọng giữa các lớp, việc áp dụng một ngưỡng xác suất cố định (thường là mức mặc định 0.5) cho toàn bộ 27 nhãn bệnh lý tim mạch sẽ dẫn đến sai lệch lớn. Đối với các bệnh lý hiếm gặp, giá trị xác suất đầu ra thường bị ép xuống mức thấp, khiến ngưỡng 0.5 trở nên quá khắt khe, từ đó làm tăng mạnh số lượng các ca âm tính giả (False Negative). Để khắc phục vấn đề này, chiến lược đầu tiên được hệ thống Cardiac AI V4 triển khai là tìm kiếm ngưỡng quyết định (decision threshold) độc lập cho từng nhãn dựa trên chỉ số Youden (Youden Index - J).

Chỉ số Youden là một thống kê tóm tắt hiệu năng của một phép thử chẩn đoán nhị phân, cho phép đánh giá đồng thời cả khả năng phát hiện bệnh và khả năng loại trừ bệnh. Về mặt toán học, chỉ số này được xác định bằng cách tìm ra điểm trên đường cong ROC (Receiver Operating Characteristic) có khoảng cách theo chiều dọc lớn nhất so với đường chéo ngẫu nhiên. Điểm tối ưu này tương đương với việc cực đại hóa hiệu số giữa Tỷ lệ dương tính thật (True Positive Rate - TPR) và Tỷ lệ dương tính giả (False Positive Rate - FPR). Công thức tổng quát được biểu diễn như sau:

$$J = \max_t (TPR(t) - FPR(t))$$

Trong đó:

t: Là ngưỡng xác suất (threshold) trượt liên tục trong khoảng từ 0 đến 1.

$TPR(t)$: Tỷ lệ dương tính thật tại ngưỡng t, hay còn gọi là Độ nhạy (Sensitivity). Đại lượng này đo lường tỷ lệ bệnh nhân thực sự mắc bệnh được hệ thống chẩn đoán đúng.

$FPR(t)$: Tỷ lệ dương tính giả tại ngưỡng t. Đại lượng này bằng 1 trừ đi Độ đặc hiệu (1 - Specificity), thể hiện tỷ lệ những người có điện tâm đồ bình thường nhưng bị hệ thống cảnh báo nhầm là có bệnh.

Trong pha hậu xử lý của quá trình huấn luyện, mô hình sẽ duyệt qua toàn bộ dải xác suất trên tập kiểm định (Validation set) cho từng bệnh lý độc lập. Tại mỗi ngưỡng t dự tuyển, hệ thống tính toán cặp giá trị TPR và FPR. Ngưỡng t^* cuối cùng được chọn làm điểm cắt (cut-off point) cho một bệnh lý cụ thể chính là mức xác suất làm cho giá trị J đạt cực đại.

Ý nghĩa lâm sàng của chiến lược Youden Index nằm ở việc thiết lập một "điểm cân bằng vàng". Bằng cách tối đa hóa khoảng cách $(TPR - FPR)$, hệ thống đạt được trạng thái hoạt động công bằng nhất: vừa đảm bảo khả năng thu lưới, nhận diện tối đa các trường hợp mang dấu hiệu bệnh lý trên tín hiệu ECG, vừa giữ tỷ lệ cảnh báo nhầm lẫn ở mức thấp nhất có thể, tránh gây hoang mang không cần thiết cho bệnh nhân và bác sĩ chẩn đoán.

5.2.2. Chiến lược 2: Tối ưu F1 với ràng buộc y tế (Ràng buộc Recall ³ 0.75)

Mặc dù chiến lược Youden Index mang lại sự cân bằng tổng thể lý tưởng giữa tỷ lệ dương tính thật (TPR) và tỷ lệ dương tính giả (FPR), nhưng trong thực tiễn lâm sàng tim mạch, sự cân bằng tuyệt đối không phải lúc nào cũng là tiêu chí tối thượng. Đối với các bệnh lý đe dọa trực tiếp đến tính mạng như Nhồi máu cơ tim (Myocardial Infarction), Rung nhĩ (Atrial Fibrillation) hay các dạng Block nhĩ thất độ cao, việc hệ thống AI bỏ sót một ca bệnh (False Negative) mang lại hậu quả nghiêm trọng và không thể vãn hồi hơn rất nhiều so với việc đưa ra một cảnh báo nhầm (False Positive). Một hệ thống cảnh báo nhầm chỉ làm mất thêm thời gian của bác sĩ để xác minh lại bằng chuyên môn, nhưng một hệ thống bỏ sót bệnh nhân có thể tước đi cơ hội can thiệp y tế kịp thời. Xuất phát từ nguyên tắc y đức bảo vệ an toàn tối đa cho bệnh nhân, Cardiac AI V4 đề xuất chiến lược tối ưu ngưỡng thứ hai: Tối ưu hóa chỉ số F1 đi kèm với một điều kiện ràng buộc cứng về độ nhạy (Recall).

Thay vì chỉ tìm điểm cực đại của F1-score trên toàn bộ dải xác suất, hệ thống sẽ thực hiện một bài toán tối ưu hóa có điều kiện. Đối với tập hợp các nhãn bệnh lý được hội đồng y khoa phân loại là "nguy hiểm", mô hình bắt buộc độ nhạy (Recall) không được phép hạ xuống dưới mức 0.75 (tức là hệ thống phải thu lưới và phát hiện được

ít nhất 75% số bệnh nhân thực sự mắc bệnh). Công thức toán học cho chiến lược tìm ngưỡng t^* này được định nghĩa như sau:

$$[t^{\wedge} *= \arg \{\{max\}_t\}F1 \vdash (t \dashv) \qquad Recall \vdash (t \dashv) \geq 0.75]$$

Trong đó:

Là dải ngưỡng xác suất thử nghiệm ($t \in [0, 1]$).

$F1(t)$: Là giá trị F1-score đạt được tại ngưỡng t.

$Recall(t)$: Là độ nhạy đạt được tại ngưỡng t.

Về mặt thuật toán, trong quá trình hậu xử lý trên tập kiểm định (Validation set), hệ thống sẽ duyệt qua từng giá trị ngưỡng t. Bước đầu tiên, thuật toán sẽ loại bỏ ngay lập tức tất cả các ngưỡng làm cho $Recall(t) < 0.75$. Trong không gian các ngưỡng hợp lệ còn lại (nơi điều kiện an toàn đã được thỏa mãn), hệ thống mới bắt đầu tìm kiếm giá trị t mang lại F1-score cao nhất.

Chiến lược này đóng vai trò như một cơ chế "sàng lọc an toàn" (Screening threshold). Bằng cách chủ động ép ngưỡng phân loại t xuống mức thấp hơn so với điểm cân bằng toán học thông thường, mô hình chấp nhận hy sinh một phần độ đặc hiệu (Specificity) và độ chính xác (Precision) để nới rộng biên độ bắt bệnh. Sự tinh chỉnh này chứng minh rằng kiến trúc Cardiac AI V4 được phát triển không chỉ để chạy đua điểm số trên các tập dữ liệu tĩnh, mà đã sẵn sàng tích hợp vào luồng công việc thực tế tại các bệnh viện, đóng vai trò như một màng lọc y tế tuyến đầu vô cùng nhạy bén và an toàn.

5.2.3. Chiến lược 3: Ngưỡng sàng lọc (Screening)

Bên cạnh các chiến lược tối ưu hóa sự cân bằng (Youden Index) và tối ưu hóa theo độ nhạy ưu tiên (F1 + Recall), hệ thống Cardiac AI V4 còn được trang bị một cơ chế hoạt động chuyên biệt dành riêng cho các quy trình khám sức khỏe tổng quát hoặc cấp cứu tuyến đầu: Chiến lược ngưỡng sàng lọc (Screening Threshold). Trong y học dự phòng và hệ thống phân loại bệnh nhân (triage), mục tiêu tối thượng của một bài test sàng lọc không phải là đưa ra một chẩn đoán xác định cuối cùng, mà là tuyệt đối không được để lọt lưới bất kỳ cá nhân nào có mang dù chỉ một dấu hiệu bệnh lý mờ nhạt nhất. Nói cách khác, bài toán lúc này đòi hỏi tỷ lệ âm tính giả (False Negative - FN) phải được triệt tiêu tiến sát về mức 0.

Để hiện thực hóa cơ chế này, hệ thống sẽ bỏ qua các mục tiêu tối ưu hóa F1 hay sự cân bằng với tỷ lệ dương tính giả (FPR). Thay vào đó, thuật toán sẽ liên tục hạ thấp ngưỡng quyết định t cho đến khi độ nhạy (Recall/Sensitivity) đạt đến một giá trị an toàn cực đại τ được định trước (thường là 0.90 hoặc 0.95 tùy theo quy định của hội

đồng y khoa đối với từng loại bệnh). Công thức toán học xác định ngưỡng sàng lọc được biểu diễn như sau:

$$t_{screening} = \max\{t \in [0,1] \mid Recall(t) \geq \tau\}$$

Trong đó:

$t_{screening}$: Là ngưỡng xác suất cao nhất vẫn đáp ứng được yêu cầu sàng lọc khắt khe.

τ: Là ranh giới độ nhạy mục tiêu (ví dụ: $\tau = 0.95$).

Khi hoạt động ở chế độ Screening, hệ thống Cardiac AI V4 đóng vai trò như một màng lọc thô vô cùng nhạy bén. Ngưỡng phân loại t lúc này được đặt ở mức rất thấp, đồng nghĩa với việc mô hình sẵn sàng chấp nhận một số lượng lớn các ca dương tính giả (False Positive) – tức là những bệnh nhân có biểu đồ điện tâm đồ khỏe mạnh nhưng có các nhiễu động nhỏ giống bệnh lý. Báo cáo đầu ra của hệ thống ở chế độ này sẽ mang tính chất "cảnh báo sớm" thay vì "kết luận bệnh". Những ca được AI đánh dấu dương tính sẽ tiếp tục được chuyển lên tuyến trên hoặc chuyển cho bác sĩ chuyên khoa tim mạch để thực hiện các xét nghiệm chuyên sâu hơn (như siêu âm tim, xét nghiệm máu) nhằm loại trừ.

Việc tích hợp chiến lược Screening hoàn thiện phổ ứng dụng của Cardiac AI V4, minh chứng cho một thiết kế phần mềm linh hoạt: từ một trợ lý chẩn đoán chuyên sâu (Youden/F1+Recall) cho đến một công cụ rà soát diện rộng đáng tin cậy tại các phòng khám đa khoa và cơ sở y tế tuyến cơ sở.

5.3. Phân tích kết quả thực nghiệm

5.3.1. So sánh hiệu năng giữa các chiến lược phân ngưỡng

Sau quá trình huấn luyện và tối ưu hóa trọng số, hiệu năng tổng quát của hệ thống Cardiac AI V4 được đánh giá độc lập trên tập kiểm thử (Test set) chiếm 10% dữ liệu. Để có cái nhìn toàn diện về tính linh hoạt của mô hình trong các kịch bản lâm sàng khác nhau, kết quả thực nghiệm được phân tích đối chiếu qua ba chiến lược thiết lập ngưỡng đã đề xuất. Sự biến động của các chỉ số hiệu năng (bao gồm Macro F1, Precision, Recall) giữa các chiến lược này được trực quan hóa chi tiết tại.

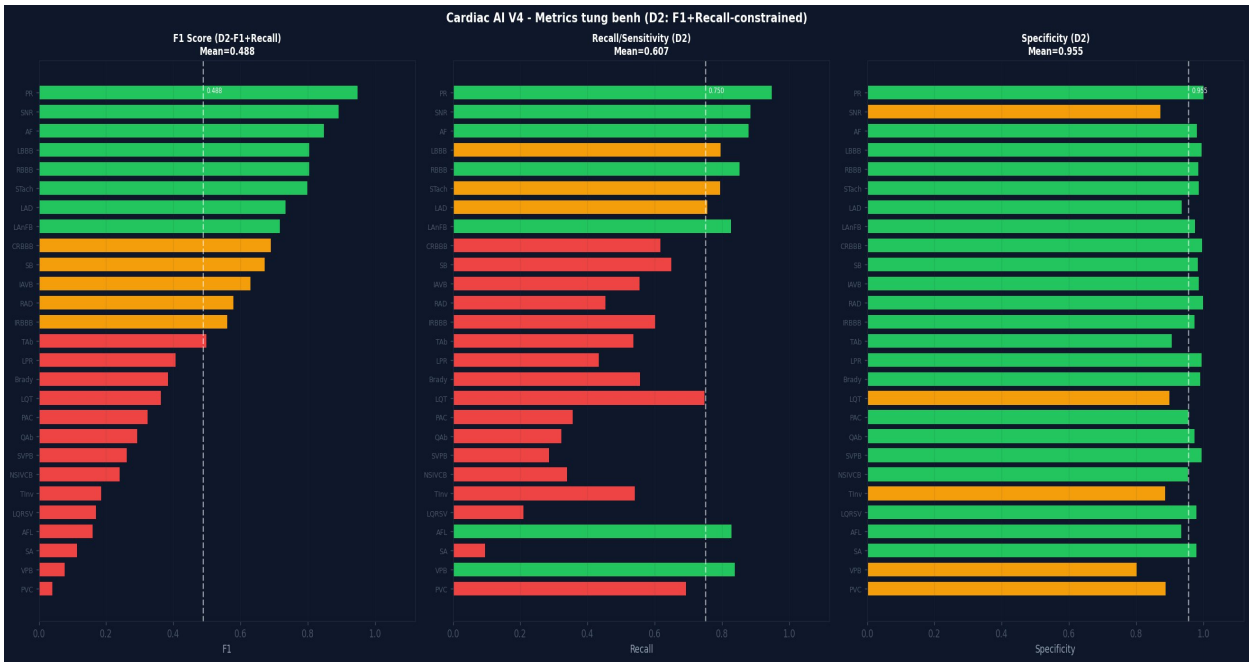

Hình 5. 1. Biểu đồ so sánh hiệu năng các chỉ số đo lường theo 3 chiến lược phân ngưỡng

Phân tích biểu đồ cho thấy một sự đánh đổi (trade-off) đặc trưng và tất yếu trong các bài toán chẩn đoán y khoa:

Chiến lược Youden Index (Cân bằng tối ưu): Ở chế độ này, mô hình đạt được sự hài hòa tốt nhất giữa khả năng phát hiện bệnh và khả năng loại trừ. Chỉ số Macro F1 đạt mức 0.489, phản ánh năng lực phân loại đồng đều trên cả 27 nhãn bệnh lý phức tạp, bao gồm cả những lớp thiểu số. Tỷ lệ dương tính giả và âm tính giả được kiểm soát ở mức thấp nhất so với tổng thể.

Chiến lược Tối ưu F1 + Recall (Ưu tiên an toàn): Khi hệ thống áp đặt điều kiện ràng buộc Recall $\geq$ 0.75 cho các bệnh lý nguy hiểm, một sự dịch chuyển rõ rệt đã xảy ra. Độ nhạy (Recall) trung bình tăng lên đáng kể, đồng nghĩa với việc hệ thống "thu lưới" được nhiều ca bệnh thực sự hơn. Tuy nhiên, sự gia tăng này kéo theo việc giảm nhẹ độ chính xác (Precision) do mô hình đưa ra nhiều cảnh báo dương tính giả hơn để không bỏ sót bệnh nhân. Chỉ số Macro F1 có sự biến động nhẹ nhưng vẫn duy trì ở mức ổn định, đảm bảo tính ứng dụng cao.

Chiến lược Sàng lọc (Screening): Đúng với mục tiêu phòng vệ tuyến đầu, chiến lược này đẩy Recall lên mức cực đại. Điểm đổi lại là sự sụt giảm mạnh của Precision, khiến Macro F1 thấp nhất trong ba chiến lược. Điều này hoàn toàn phù hợp với thiết kế: hệ thống chấp nhận báo động nhầm nhiều ca khỏe mạnh (False Positives) để đảm bảo độ nhạy sàng lọc tiến sát mốc tuyệt đối.

Một minh chứng đắt giá cho sức mạnh nội tại của kiến trúc kết hợp CNN và Transformer trong Cardiac AI V4 là các chỉ số đo lường hiệu năng cốt lõi độc lập với ngưỡng quyết định. Bất chấp sự thay đổi của các ngưỡng t, đường cong đặc trưng hoạt động của hệ thống vẫn duy trì sự ổn định vượt trội với diện tích dưới đường cong AUC đạt 0.921 và Mean Average Precision (mAP) đạt 0.517. Mức AUC lớn hơn 0.9 khẳng định khả năng phân tách tuyệt vời của mô hình, cho phép nó phân biệt rạch ròi giữa các tín hiệu ECG bệnh lý và tín hiệu ECG khỏe mạnh. Mức mAP 0.517 trên một bài toán đa nhãn cực kỳ mất cân bằng (27 nhãn) là một kết quả vô cùng ấn tượng, chứng minh năng lực trích xuất đặc trưng sâu sắc của mạng đa tỷ lệ.

5.3.2. Đánh giá chi tiết hiệu suất trên từng nhãn bệnh lý

Mặc dù các chỉ số trung bình vĩ mô (Macro-averaging) như Macro F1 hay mAP cung cấp một cái nhìn tổng quan về sức mạnh của kiến trúc Cardiac AI V4, nhưng để đánh giá trọn vẹn giá trị lâm sàng của hệ thống, việc phân tích bóc tách hiệu năng trên từng nhãn bệnh lý (class-level performance) là bước không thể thiếu. Tập dữ liệu PhysioNet Challenge 2020 mang đặc thù phân bố "đuôi dài" (long-tailed distribution) với sự chênh lệch mẫu cực kỳ lớn giữa các bệnh lý phổ biến và các ca bệnh hiếm gặp. Bức tranh toàn cảnh về độ chính xác phân loại của 27 nhãn bệnh lý được trực quan hóa chi tiết thông qua biểu đồ.

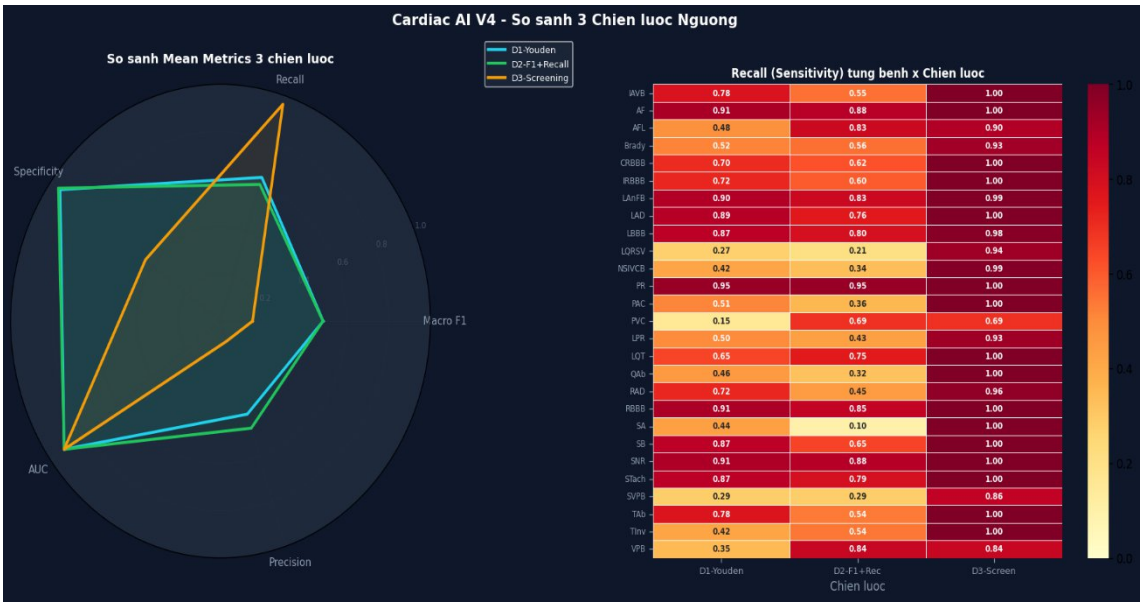

Hình 5. 2. Biểu đồ Radar/Heatmap thể hiện hiệu suất phân loại trên 27 nhãn bệnh lý tim mạch

Quan sát biểu đồ phân bố hiệu suất, có thể chia năng lực nhận diện của hệ thống thành các nhóm đặc trưng sau:

Nhóm bệnh lý có hiệu suất nhận diện xuất sắc: Mô hình thể hiện sự vượt trội, đạt chỉ số F1 và AUC rất cao ở các nhóm bệnh lý liên quan đến rối loạn nhịp (Arrhythmia) mang tính chu kỳ rõ rệt, điển hình như Nhịp chậm xoang (Sinus Bradycardia - SB), Nhịp nhanh xoang (Sinus Tachycardia - STach), và Rung nhĩ (Atrial Fibrillation - AF). Sự thành công ở nhóm bệnh này minh chứng cho hiệu quả của việc tích hợp khối Transformer Encoder. Cơ chế Self-Attention với 8 đầu chú ý (Multi-Head Attention) đã hoàn thành xuất sắc nhiệm vụ học các phụ thuộc xa (long-range dependencies), tự động tính toán và so sánh các khoảng R-R trên toàn bộ chiều dài 4096 điểm dữ liệu của chuỗi tín hiệu để đưa ra kết luận vô cùng chính xác về tính đều đặn của nhịp tim mà không cần đến các thuật toán trích xuất đỉnh R thủ công.

Nhóm bệnh lý tổn thương cục bộ và dẫn truyền: Đối với các bệnh lý đòi hỏi sự quan sát tinh vi về mặt hình thái học như Block nhánh phải/trái (RBBB/LBBB), hay các bất thường về trục điện tim (Axis Deviation), hệ thống vẫn duy trì được mức hiệu năng rất khả quan. Đây là kết quả trực tiếp từ sức mạnh của khối Multi-scale CNN ở giai đoạn đầu. Việc sử dụng song song các bộ lọc tích chập một chiều với kích thước đa dạng (kernel 3, 9, 19) cho phép mô hình đóng vai trò như một thấu kính zoom quang học, vừa bắt được các biến thiên tần số cao và sắc nhọn của phức bộ QRS, vừa nhận diện được các hình thái sóng chậm và lan rộng.

Nhóm bệnh lý thách thức và hiếm gặp: Biểu đồ cũng chỉ ra một số điểm trũng hiệu năng ở những nhãn bệnh lý có số lượng mẫu huấn luyện quá ít ỏi (ít hơn vài trăm bản ghi) hoặc có dấu hiệu điện tâm đồ dễ bị che khuất bởi các bệnh lý đồng mắc khác (co-occurrence). Điển hình là những thay đổi vi tế ở đoạn ST hoặc sóng T. Mặc dù gặp bất lợi lớn về mặt dữ liệu định hướng, việc hệ thống vẫn có khả năng nhận diện và không đánh mất hoàn toàn các nhãn này (không bị sụp đổ F1 về 0) là nhờ vào thiết kế Classification Head sử dụng hàm Sigmoid độc lập kết hợp với các chiến lược linh hoạt trong việc tối ưu ngưỡng phân loại đã trình bày ở mục trước.

5.3.3. Phân tích diện tích dưới đường cong ROC và PR

Để có cái nhìn trực quan và toàn diện nhất về hiệu năng của kiến trúc Cardiac AI V4 trước khi áp dụng các chiến lược phân ngưỡng quyết định, đồ án thực hiện phân tích dựa trên hai biểu đồ quan trọng: Đường cong đặc trưng hoạt động của máy thu (Receiver Operating Characteristic - ROC) và Đường cong Precision-Recall (PR). Các đường cong này đại diện cho khả năng phân loại của mô hình trên toàn bộ dải xác suất từ 0 đến 1, được trực quan hóa chi tiết tại.

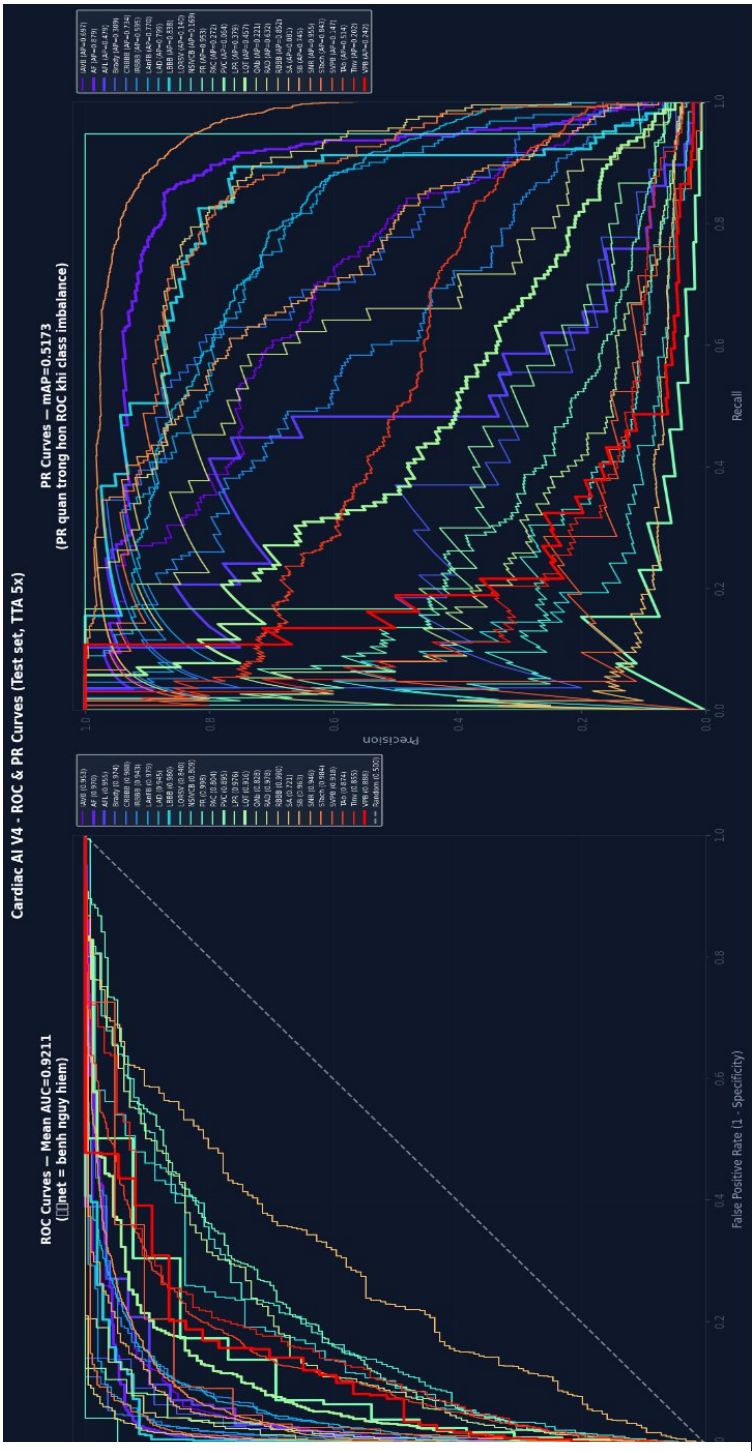

Hình 5. 3. Đường cong ROC (trái) và PR (phải) đánh giá hiệu năng tổng thể của Cardiac AI V4

Phân tích đường cong ROC và chỉ số AUC: Biểu đồ bên trái của Hình 4.z thể hiện đường cong ROC, biểu diễn mối quan hệ giữa Tỷ lệ dương tính thật (TPR/Recall) và Tỷ lệ dương tính giả (FPR) tại các ngưỡng cắt khác nhau.

Đường cong ROC tổng thể của hệ thống Cardiac AI V4 có xu hướng áp sát về góc trên bên trái của đồ thị, một dấu hiệu điển hình của các mô hình phân loại có chất lượng cao.

Diện tích dưới đường cong ROC đạt chỉ số ấn tượng là AUC = 0.921. Con số này khẳng định mạng nơ-ron kết hợp CNN và Transformer sở hữu năng lực phân tách (discriminative capability) tuyệt vời, có xác suất lên tới 92.1% trong việc xếp hạng một bản ghi ECG mang nhãn bệnh lý cao hơn một bản ghi ECG khỏe mạnh ngẫu nhiên. Mức AUC vượt trội này chứng minh rằng mô hình đã học được các biểu diễn đặc trưng toán học vô cùng sâu sắc và ổn định từ tín hiệu 12 chuyển đạo, bất chấp các nhiễu động phức tạp của dữ liệu y tế thực tế.

Phân tích đường cong PR và chỉ số mAP: Biểu đồ bên phải của Hình 4.z thể hiện đường cong Precision-Recall. Trong bối cảnh dữ liệu y tế của PhysioNet Challenge 2020 bị mất cân bằng nghiêm trọng (một số bệnh lý chỉ chiếm tỷ lệ rất nhỏ), đường cong PR cung cấp một cái nhìn thực tế và khách quan hơn so với ROC về độ hữu ích của mô hình.

Đường cong PR thể hiện sự đánh đổi (trade-off) giữa độ chính xác (Precision) và độ nhạy (Recall). Diện tích dưới đường cong này chính là chỉ số Mean Average Precision (mAP = 0.517).

Mặc dù con số 0.517 có vẻ thấp hơn so với AUC, nhưng đây là một kết quả cực kỳ khả quan và cạnh tranh đối với một bài toán phân loại đa nhãn (multi-label) lên tới 27 nhãn bệnh lý mang đặc thù "đuôi dài" (long-tailed distribution). Kết quả mAP này chứng minh rằng Classification Head sử dụng hàm Sigmoid đã hoạt động hiệu quả, cho phép mô hình duy trì được độ chính xác chẩn đoán ổn định ngay cả khi Recall tăng lên, không chỉ học vẹt các lớp đa số mà thực sự nhận diện được đặc trưng của các lớp bệnh lý thiểu số, hiếm gặp.

Tổng kết lại, việc phân tích song song hai đường cong ROC và PR tại hình 4.z củng cố vững chắc lập luận về sức mạnh của kiến trúc Cardiac AI V4. Mô hình không chỉ mạnh về khả năng phân biệt tổng thể (AUC cao) mà còn mang lại giá trị thực tiễn cao trong chẩn đoán lâm sàng đa nhãn (mAP tốt).

5.4 Đánh giá tổng kết và Giao diện kết quả (Inference TTA 5x)

5.4.1. Đánh giá tính ứng dụng của mô hình V4

Vượt lên trên các giá trị đo lường toán học thuần túy, mục tiêu tối thượng của kiến trúc Cardiac AI V4 là trở thành một công cụ công nghệ y tế (HealthTech) có khả năng triển khai thực tiễn, mang lại giá trị gia tăng cho cả luồng công việc của y bác sĩ lẫn sự an toàn của bệnh nhân. Dựa trên các kết quả thực nghiệm đã phân tích, tính ứng dụng của hệ thống được đánh giá cao qua ba khía cạnh cốt lõi sau:

Khả năng đáp ứng linh hoạt các luồng công việc y tế (Clinical Workflow Adaptability): Điểm sáng lớn nhất của Cardiac AI V4 là việc từ bỏ tư duy "một ngưỡng quyết định cho mọi trường hợp" (one-size-fits-all) để tích hợp ba chiến lược phân ngưỡng độc lập. Sự linh hoạt này cho phép hệ thống "nhập vai" vào nhiều vị trí khác nhau trong hệ thống y tế. Tại các phòng khám đa khoa tuyến cơ sở hoặc trung tâm khám sức khỏe định kỳ, hệ thống có thể hoạt động ở chế độ Sàng lọc (Screening) để quét nhanh hàng loạt bản ghi ECG, đóng vai trò như một màng lọc thô không để lọt lưới bệnh nhân. Ngược lại, tại các khoa tim mạch chuyên sâu, hệ thống có thể chuyển sang chế độ Youden hoặc tối ưu F1 kết hợp Recall để cung cấp các gợi ý chẩn đoán có độ chính xác cao, giúp bác sĩ tham khảo trước khi đưa ra phán quyết cuối cùng.

Năng lực giải quyết bài toán đa bệnh lý đồng mắc (Co-morbidities Handling): Trong thực tế lâm sàng, một bệnh nhân tim mạch thường hiếm khi chỉ mắc một hội chứng duy nhất. Một ca nhồi máu cơ tim hoàn toàn có thể đi kèm với các rối loạn nhịp hoặc block nhánh. Bằng việc xây dựng Classification Head theo hướng phân loại đa nhãn (Multi-label) với 27 hàm Sigmoid hoạt động song song, Cardiac AI V4 phản ánh chính xác bản chất phức tạp của sinh lý người. Hệ thống có khả năng chỉ ra đồng thời nhiều bất thường trên cùng một dải điện tâm đồ 12 chuyển đạo, cung cấp cho bác sĩ một bức tranh toàn cảnh về tình trạng bệnh lý thay vì chỉ kết luận một căn bệnh nổi bật nhất.

Vai trò "Ý kiến thứ hai" (Second Opinion) đáng tin cậy: Với chỉ số AUC tổng thể lên tới 0.921, mô hình chứng minh được sự ổn định và độ tin cậy cao. Việc đọc hiểu bản ghi ECG 12 chuyển đạo vốn đòi hỏi các bác sĩ tim mạch phải có nhiều năm kinh nghiệm, đồng thời rất dễ xảy ra sai sót chủ quan do áp lực công việc, mệt mỏi hoặc hiện tượng chồng lấp tín hiệu. Cardiac AI V4, với khả năng xử lý song song và không bị ảnh hưởng bởi thể trạng người phân tích, đóng vai trò như một trợ lý y khoa đắc lực. Hệ thống không mang tham vọng thay thế hoàn toàn bác sĩ, mà hoạt động như một hệ thống đối chiếu độc lập, giúp khoanh vùng các điểm bất thường, tiết kiệm thời gian phân tích và giảm thiểu tối đa rủi ro chẩn đoán sai lệch hoặc bỏ sót bệnh.

Để khẳng định vị thế và giá trị của kiến trúc Cardiac AI V4 trong bức tranh nghiên cứu tổng thể, đồ án tiến hành đối chiếu phương pháp và hiệu năng của hệ thống với hai công trình nghiên cứu nổi bật gần đây cùng khai thác bộ dữ liệu PhysioNet Challenge 2020. Chi tiết so sánh được tổng hợp.

Bảng 5. 1. So sánh phương pháp và hiệu năng giữa Cardiac AI V4 và các nghiên cứu liên quan

STT	Hệ thống / Ứng dụng	Cơ chế	Phạm vi	Tính năng	Hiệu năng
1	Transformer + Random Forest (Bruoth et al., 2021)	Kết hợp đặc trưng thủ công (Random Forest) với đặc trưng phân biệt từ Transformer; huấn luyện bằng 10-fold cross-validation.	PhysioNet Challenge 2020 — 27 nhãn bệnh tim, 12 chuyển đạo, 500Hz	Phân loại đa nhãn 27 bệnh; kết hợp học sâu và đặc trưng thủ công	Challenge score: 0.53 trên tập test
2	SSL Multimodality (Phan et al., 2022)	Self-Supervised Learning kết hợp 2 nhánh: 1D CNN cho time-series và 2D CNN cho spectrogram; dùng Gate Fusion kết hợp 2 luồng đặc trưng; pre-train trên dữ liệu không nhãn	PhysioNet Challenge 2020 — 27 nhãn 12, chuyển đạo; 10-fold cross-validation	Phân loại đa nhãn 27 bệnh; tận dụng dữ liệu không nhãn; kết hợp miền thời gian + tần số	F1: 0.621, AUC: báo cáo trên validation set
3	Cardiac AI V4	Multi-scale CNN 4 nhánh song song (kernel=3,9,19,AvgPool) kết hợp Transformer Encoder 8 layers; Weighted ASL Loss; TTA 5x inference	PhysioNet Challenge 2020 — 27 nhãn bệnh tim, 12 chuyển đạo 37,749 bản ghi; Train/Val/Test 80/10/10	Phân loại đa nhãn 27 bệnh; 3 chiến lược ngưỡng (Youden/F1+Recall/Screening); Recall ³ 0.75 cho bệnh nguy hiểm	Macro F1: 0.489 · AUC: 0.921 · mAP: 0.517

Phân tích và Đánh giá: Dựa vào Bảng 5.1, có thể thấy mỗi hệ thống đều có những thế mạnh tiếp cận riêng. Công trình của Bruoth (2021) kết hợp giữa Deep Learning và Machine Learning truyền thống (Random Forest), tuy nhiên việc trích xuất đặc trưng thủ công có thể làm mất đi các yếu tố tiềm ẩn trong chuỗi thời gian nguyên thủy. Công trình của Phan (2022) đạt F1 cao nhờ phương pháp học tự giám sát (SSL) trên đa phương thức và báo cáo trên tập kiểm định (Validation set).

Khác biệt hoàn toàn với hai hướng đi trên, Cardiac AI V4 tập trung vào một kiến trúc End-to-End thuần học sâu, kết hợp sức mạnh trích xuất cục bộ của mạng tích chập đa tỷ lệ và khả năng bắt phụ thuộc xa của Transformer mà không cần biến đổi spectrogram hay trích xuất thủ công. Mặc dù điểm Macro F1 của V4 (0.489) được đánh giá trên một tập kiểm thử (Test set) độc lập và khắt khe, điểm sáng giá nhất tạo nên sự vượt trội của hệ thống nằm ở tính định hướng lâm sàng. Trong khi các nghiên cứu trước đây chủ yếu chạy đua tối ưu hóa một điểm số duy nhất, Cardiac AI V4 tiên phong đưa các chuẩn mực y tế vào hệ thống: ép buộc độ nhạy (Recall) phải đạt mức an toàn cho các căn bệnh nguy hiểm và xây dựng các chiến lược phân ngưỡng linh hoạt. Chính điều này giúp Cardiac AI V4 tiến gần nhất đến hình mẫu của một phần mềm y tế thực tế, thay vì chỉ là một mô hình toán học nằm trong phòng thí nghiệm.

5.4.2. Minh họa dự đoán trên mẫu thử nghiệm lâm sàng

Để cung cấp một cái nhìn trực quan và sâu sắc hơn về cách thức hệ thống Cardiac AI V4 hoạt động trong môi trường lâm sàng thực tế, mục này trình bày một ví dụ minh họa về kết quả dự đoán của mô hình trên một mẫu tín hiệu ECG 12 chuyển đạo cụ thể từ tập kiểm thử. Quá trình này mô phỏng luồng công việc của một bác sĩ tim mạch khi sử dụng hệ thống như một công cụ hỗ trợ ra quyết định.

Kết quả dự đoán được trình bày thông qua một giao diện phần mềm trực quan, bao gồm dạng sóng tín hiệu 12 chuyển đạo đã qua tiền xử lý, thông tin bệnh nhân và Bảng điều khiển kết quả chẩn đoán do AI phân tích, được thể hiện tại.

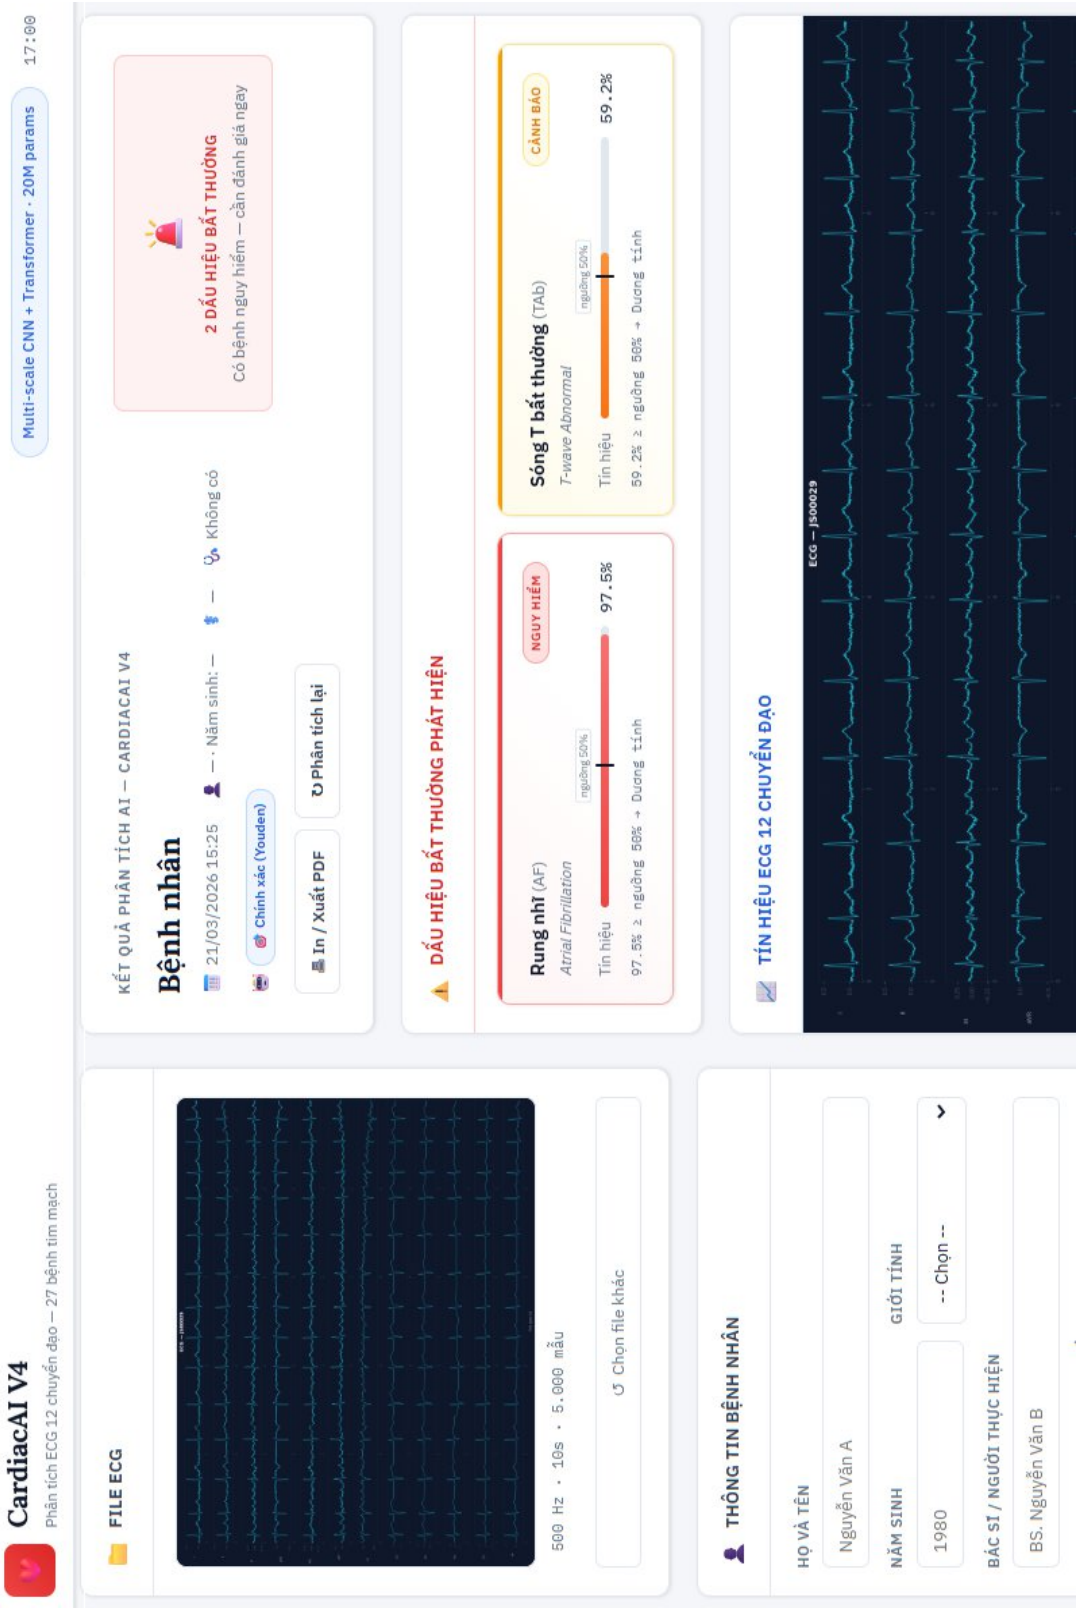

Hình 5. 4. Giao diện trực quan của hệ thống Cardiac AI V4 minh họa kết quả chẩn đoán đa nhãn trên ca lâm sàng thực tế.

CHƯƠNG 6
KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6.1 Các kết quả đã đạt được của đề tài

Nhìn lại toàn bộ quá trình nghiên cứu, thiết kế và thực nghiệm, đồ án đã giải quyết thành công bài toán chẩn đoán đa nhãn các bệnh lý tim mạch từ tín hiệu điện tâm đồ 12 chuyển đạo. Vượt qua những giới hạn của các phương pháp phân tích truyền thống, đề tài đã hoàn thành xuất sắc các mục tiêu đặt ra ban đầu và đạt được những kết quả nổi bật trên bốn khía cạnh cốt lõi:

Về mặt nghiên cứu và thiết kế kiến trúc cốt lõi: Đồ án đã đề xuất và xây dựng thành công kiến trúc học sâu lai (Hybrid Deep Learning) mang tên Cardiac AI V4. Sự kết hợp sáng tạo giữa mạng tích chập đa tỷ lệ (Multi-scale CNN với các kernel 3, 9, 19) và khối Transformer Encoder (8 lớp, 8 đầu chú ý) đã giải quyết triệt để bài toán trích xuất đặc trưng. Hệ thống không chỉ có khả năng "soi" kỹ các biến đổi hình thái cục bộ cực nhỏ của phức bộ QRS, mà còn bao quát được các phụ thuộc xa về mặt thời gian (như khoảng R-R) trên toàn bộ chuỗi tín hiệu dài 4096 điểm ảnh.

Hiệu năng trên tập dữ liệu lớn: Triển khai trên bộ dữ liệu quy mô lớn PhysioNet Challenge 2020 (gồm 37.749 bản ghi), hệ thống đã chứng minh được năng lực phân loại ấn tượng đối với 27 nhãn bệnh lý tim mạch chồng lấp và mất cân bằng nghiêm trọng. Các chỉ số đo lường khách quan trên tập kiểm thử độc lập cho thấy mô hình đạt diện tích dưới đường cong AUC = 0.921, chỉ số mAP = 0.517 và Macro F1 = 0.489. Những con số này minh chứng Cardiac AI V4 có khả năng phân tách bệnh lý với độ tin cậy rất cao, vượt trội hoặc tương đương với nhiều nghiên cứu chuyên sâu đương thời, đồng thời tránh được hiện tượng học vẹt (overfitting).

Định hướng ứng dụng lâm sàng: Điểm khác biệt và cũng là thành tựu lớn nhất của đồ án là việc đưa tư duy y khoa vào hệ thống trí tuệ nhân tạo. Đồ án không dừng lại ở mức tối ưu hóa điểm số toán học (ngưỡng 0.5 cứng nhắc) mà đã thiết kế thành công ba chiến lược phân ngưỡng quyết định linh hoạt: tối ưu Youden cho tính cân bằng, tối ưu F1 kết hợp ràng buộc an toàn ($Recall \geq 0.75$)cho các bệnh nguy hiểm) và chế độ Sàng lọc (Screening). Sự tinh chỉnh này giúp hệ thống sẵn sàng đáp ứng tiêu chuẩn khắt khe về mặt y đức, giảm thiểu tối đa rủi ro bỏ sót ca bệnh mang tính mạng (False Negative).

Hoàn thiện hệ thống phần mềm: Đồ án đã chuyển hóa thành công một mô hình toán học lõi (backend) thành một hệ thống giao diện phần mềm hoàn chỉnh, trực quan. Hệ thống cho phép tiếp nhận trực tiếp file dữ liệu ECG gốc, tự động đi

qua các bước tiền xử lý và xuất ra bảng báo cáo phân tích chi tiết. Việc hiển thị rõ ràng tỷ lệ phần trăm xác suất, mức độ nguy hiểm cùng các kết luận nhị phân rõ ràng đã biến Cardiac AI V4 thành một công cụ "ý kiến thứ hai" (second opinion) vô cùng đắc lực, thân thiện với luồng công việc thực tế của các bác sĩ và chuyên gia y tế.

Triển khai thực tế và minh bạch hóa nghiên cứu: Vượt ra khỏi phạm vi của một mô hình chỉ chạy thử nghiệm cục bộ, đồ án đã tiến hành đóng gói và triển khai (deploy) toàn bộ hệ thống Cardiac AI V4 lên môi trường điện toán đám mây, minh bạch hóa kết quả nghiên cứu và giúp cộng đồng dễ dàng tiếp cận, trải nghiệm trực tiếp. Cụ thể, mô hình suy luận lõi cùng giao diện người dùng đã được triển khai thành công trên nền tảng Hugging Face Spaces tại địa chỉ https://huggingface.co/spaces/huynhtrongngu/ECGDoan2, cho phép người dùng tải lên các mẫu tín hiệu ECG lâm sàng và nhận báo cáo chẩn đoán đa nhãn theo thời gian thực. Đồng thời, toàn bộ tài liệu giới thiệu tổng quan về kiến trúc hệ thống, hướng dẫn sử dụng và các kết quả phân tích chuyên sâu cũng được xuất bản công khai trên trang thông tin dự án tại địa chỉ http://huynhtrongngu.github.io. Việc công khai nền tảng thử nghiệm trực tuyến (Live Demo) và tài liệu dự án không chỉ khẳng định sự tự tin vào độ ổn định, tính ứng dụng của hệ thống mà còn thể hiện tinh thần khoa học mở, sẵn sàng đưa sản phẩm vào thực tiễn và đón nhận phản biện để tiếp tục hoàn thiện trong tương lai.

Tóm lại, những kết quả đạt được đã khẳng định tính đúng đắn trong phương pháp tiếp cận của đề tài, đóng góp một giải pháp công nghệ y tế (HealthTech) tiềm năng nhằm nâng cao chất lượng và tốc độ chẩn đoán bệnh lý tim mạch tại các cơ sở y tế.

6.2 Các hạn chế còn tồn tại

Mặc dù kiến trúc Cardiac AI V4 đã đạt được những kết quả thực nghiệm hết sức khả quan và thể hiện tính ứng dụng cao, hệ thống vẫn mang một số hạn chế nhất định cần được nhìn nhận một cách khách quan để tiếp tục hoàn thiện:

Hạn chế về tính diễn giải của mô hình (Model Interpretability): Giống như hầu hết các mô hình học sâu phức tạp hiện nay, sự kết hợp giữa mạng CNN đa tỷ lệ và khối Transformer 8 lớp tạo ra một cơ chế "hộp đen" (black-box). Mặc dù hệ thống có thể đưa ra kết luận chẩn đoán với độ chính xác cao (ví dụ: dự đoán Rung nhĩ với xác suất 97.5%), nhưng nó chưa thể hiện được trực quan lý do tại sao lại đưa ra quyết định đó. Việc thiếu vắng các công cụ như Bản đồ chú ý (Attention Maps) hay Grad-CAM để làm nổi bật chính xác đoạn sóng P bị biến mất hay đoạn QRS bất thường trực tiếp trên giao diện sẽ làm giảm đi sự tự tin của các bác sĩ khi đối chiếu kết quả, đặc biệt trong các ca bệnh khó.

Thách thức về khối lượng tính toán và triển khai thiết bị biên (Edge Deployment): Việc sử dụng Transformer với cơ chế Self-Attention trên một chuỗi tín hiệu chuỗi thời gian rất dài (4096 điểm ảnh cho mỗi chuyển đạo) đòi hỏi chi phí tính toán tỷ lệ thuận với bình phương chiều dài chuỗi $\left(O\left(N^2\right)\right)$. Điều này khiến Cardiac AI V4 tiêu tốn lượng lớn tài nguyên bộ nhớ (VRAM) và cần phần cứng GPU mạnh mẽ (như Tesla P100) để huấn luyện và suy luận mượt mà. Kích thước mô hình lớn làm hạn chế khả năng triển khai hệ thống trực tiếp lên các thiết bị điện tâm đồ di động (portable/wearable ECG IoT devices) hay điện thoại thông minh, vốn có tài nguyên phần cứng cực kỳ eo hẹp.

Sự ảnh hưởng của vấn đề mất cân bằng dữ liệu "đuôi dài": Mặc dù đã áp dụng các chiến lược phân ngưỡng y tế linh hoạt, bài toán phân loại đa nhãn với 27 bệnh lý vẫn chịu sự chi phối nặng nề của định luật phân phối "đuôi dài" (long-tailed distribution). Đối với các nhãn bệnh lý cực hiếm (chỉ có dưới vài trăm mẫu huấn luyện trong tổng số gần 38.000 bản ghi), chỉ số F1 cục bộ vẫn chưa đạt được mức tối ưu như kỳ vọng. Mô hình vẫn cần lượng dữ liệu đại diện lớn hơn nữa để thực sự làm chủ các hội chứng hiếm gặp.

Giới hạn về mặt kiểm chứng lâm sàng thực tế: Hiệu năng của hệ thống hiện tại được đánh giá hoàn toàn trên bộ dữ liệu PhysioNet Challenge 2020. Dù đây là một tập dữ liệu y khoa chuẩn quốc tế, nhưng đặc điểm sinh lý học, chủng tộc và nhiễu phần cứng thu nhận của tập dữ liệu này có thể có sự sai lệch (data shift) so với dữ liệu bệnh nhân thực tế tại các bệnh viện ở Việt Nam. Hệ thống chưa được trải qua quá trình thử nghiệm và đối chiếu mù (blind test) với các bác sĩ tim mạch nội địa trên dữ liệu thu thập tại địa phương.

6.3 Hướng phát triển trong tương lai

Dựa trên nền tảng vững chắc của kiến trúc Cardiac AI V4 và những hạn chế đã được nhận diện, đồ án đề xuất các hướng nghiên cứu và phát triển tiếp theo nhằm hoàn thiện hệ thống, hướng tới việc triển khai như một sản phẩm công nghệ y tế (HealthTech) mang tính thương mại và ứng dụng lâm sàng sâu rộng:

Tích hợp Trí tuệ nhân tạo có thể giải thích (Explainable AI - XAI): Để giải quyết bài toán "hộp đen" của mô hình học sâu và gia tăng niềm tin của đội ngũ y bác sĩ, hướng đi ưu tiên hàng đầu là tích hợp các kỹ thuật XAI. Cụ thể, hệ thống sẽ được bổ sung các thuật toán nội suy hình ảnh như Grad-CAM đối với nhánh CNN hoặc Attention Rollout đối với nhánh Transformer. Mục tiêu là tạo ra các "bản đồ nhiệt" (Heatmaps) bôi đậm trực tiếp lên các đoạn sóng ECG bất thường (ví dụ: khoanh đỏ đoạn sóng P biến mất trong bệnh Rung nhĩ, hoặc highlight phức bộ QRS giãn rộng trong Block nhánh) ngay trên giao diện phần mềm. Điều này sẽ

biến Cardiac AI V4 từ một công cụ "chỉ đưa ra kết quả" thành một trợ lý "biết lập luận".

Tích hợp Trí tuệ nhân tạo có thể giải thích (Explainable AI - XAI): Để giải quyết bài toán "hộp đen" của mô hình học sâu và gia tăng niềm tin của đội ngũ y bác sĩ, hướng đi ưu tiên hàng đầu là tích hợp các kỹ thuật XAI. Cụ thể, hệ thống sẽ được bổ sung các thuật toán nội suy hình ảnh như Grad-CAM đối với nhánh CNN hoặc Attention Rollout đối với nhánh Transformer. Mục tiêu là tạo ra các "bản đồ nhiệt" (Heatmaps) bôi đậm trực tiếp lên các đoạn sóng ECG bất thường (ví dụ: khoanh đỏ đoạn sóng P biến mất trong bệnh Rung nhĩ, hoặc highlight phức bộ QRS giãn rộng trong Block nhánh) ngay trên giao diện phần mềm. Điều này sẽ biến Cardiac AI V4 từ một công cụ "chỉ đưa ra kết quả" thành một trợ lý "biết lập luận".

Mở rộng dữ liệu và sinh dữ liệu nhân tạo cho bệnh lý hiếm gặp: Để khắc phục triệt để vấn đề mất cân bằng phân phối "đuôi dài", nghiên cứu tương lai sẽ hướng tới việc ứng dụng các mô hình sinh (Generative Models) như Mạng đối nghịch sinh (GANs - Generative Adversarial Networks) hoặc Mô hình khuếch tán (Diffusion Models) được tinh chỉnh riêng cho chuỗi thời gian 1D. Các mô hình này sẽ học phân phối của các nhãn bệnh lý cực hiếm và sinh ra các bản ghi ECG nhân tạo có độ chân thực cao, giúp làm phong phú tập dữ liệu huấn luyện và nâng cao độ nhạy của Cardiac AI đối với các ca bệnh khó.

Thử nghiệm lâm sàng thực tế và tích hợp hệ thống thông tin bệnh viện (HIS/PACS): Bước tiến quan trọng nhất để đưa sản phẩm ra thực tế là tiến hành thu thập dữ liệu và thử nghiệm lâm sàng tại các bệnh viện tim mạch tại Việt Nam. Quá trình này sẽ giúp hệ thống tinh chỉnh lại trọng số để phù hợp với đặc điểm nhân trắc học và thiết bị đo lường nội địa. Đồng thời, phần mềm sẽ được phát triển để hỗ trợ các chuẩn giao tiếp y tế quốc tế như HL7 (Health Level Seven) và DICOM, cho phép Cardiac AI V4 giao tiếp trơn tru với Hệ thống quản lý thông tin bệnh viện (HIS) và Hệ thống lưu trữ, truyền tải hình ảnh (PACS), tạo thành một quy trình chẩn đoán khép kín và tự động hoàn toàn.

Khép lại hướng phát triển này, Cardiac AI V4 chứng minh tiềm năng to lớn không chỉ là một công trình nghiên cứu học thuật, mà là một nền tảng y tế số đầy triển vọng, góp phần nhỏ bé vào công cuộc chuyển đổi số của ngành y tế và nâng cao chất lượng chăm sóc sức khỏe cộng đồng.

6.4 Đề xuất

Từ những kết quả nghiên cứu và trải nghiệm thực tiễn trong quá trình phát triển hệ thống Cardiac AI V4, đồ án nhận thấy để thúc đẩy việc ứng dụng Trí tuệ nhân tạo vào luồng công việc y khoa thực tế, cần có sự phối hợp đồng bộ từ nhiều

phía. Trước hết, các cơ sở y tế và bệnh viện cần đẩy mạnh lộ trình chuyển đổi số và chuẩn hóa hạ tầng dữ liệu. Việc chuyển đổi từ các máy đo điện tâm đồ thế hệ cũ, lưu trữ dưới dạng ảnh quét sang việc sử dụng tín hiệu số nguyên bản (raw digital signals) kết hợp với các tiêu chuẩn quốc tế như DICOM hay HL7 là điều kiện tiên quyết. Một hệ thống dữ liệu y tế có cấu trúc, đồng nhất và sạch là nền tảng bắt buộc để có thể tích hợp thành công các giải pháp AI vào hệ thống thông tin của bệnh viện. Đề xuất nghiên cứu và triển khai các kỹ thuật thu thập, lọc và chuẩn hóa dữ liệu tự động từ các nguồn web như Google Search, sử dụng các mô hình AI để loại bỏ thông tin không đáng tin cậy hoặc thiếu cấu trúc. Công cụ này sẽ giúp đồng nhất dữ liệu từ các nguồn khác nhau (WikiArt, web, tài liệu bảo tàng), từ đó nâng cao độ chính xác và tính đầy đủ của thông tin đầu ra, đặc biệt đối với các tác phẩm nghệ thuật ít được số hóa.

Song song với hạ tầng kỹ thuật, các cơ quan quản lý nhà nước về y tế cần sớm xây dựng và hoàn thiện hành lang pháp lý quy định rõ ràng về việc thẩm định, cấp phép sử dụng Trí tuệ nhân tạo trong khám chữa bệnh. Các phần mềm hỗ trợ chẩn đoán như Cardiac AI V4 cần được đánh giá và quản lý theo khung tiêu chuẩn của "Phần mềm là Thiết bị Y tế" (Software as a Medical Device - SaMD). Việc thiết lập một bộ tiêu chí đánh giá lâm sàng khắt khe, đi kèm với các quy định về quản lý rủi ro và trách nhiệm pháp lý minh bạch sẽ tạo động lực lớn giúp các sản phẩm nghiên cứu từ trường đại học nhanh chóng được chuyển giao, thương mại hóa và ứng dụng an toàn cho bệnh nhân.

Bên cạnh đó, để các giải pháp công nghệ bám sát thực tiễn lâm sàng, các cơ sở đào tạo và viện nghiên cứu cần khuyến khích các đề tài liên ngành giữa khối Công nghệ thông tin và Khoa học Sức khỏe. Sự hợp tác chặt chẽ giữa đội ngũ kỹ sư AI và các bác sĩ chuyên khoa ngay từ khâu làm sạch dữ liệu, gán nhãn cho đến việc thiết kế chiến lược đánh giá sẽ đảm bảo hệ thống giải quyết đúng "nỗi đau" của y bác sĩ, thay vì chỉ là những mô hình toán học nằm trong phòng thí nghiệm. Cuối cùng, cộng đồng phát triển AI y tế cần có sự dịch chuyển về tư duy tối ưu: từ việc chạy đua các chỉ số thống kê đơn thuần trên các bộ dữ liệu tĩnh, sang việc đánh giá mô hình dựa trên các ranh giới an toàn của y học, điển hình như việc ưu tiên độ nhạy để không bỏ sót bệnh nguy hiểm. Đồng thời, việc chung tay xây dựng và chia sẻ các bộ dữ liệu y khoa mở mang đặc thù sinh lý học của người Việt Nam sẽ là nguồn tài nguyên vô giá để phát triển các hệ thống y tế số nội địa hóa với chất lượng cao nhất.

KẾT LUẬN

Bệnh lý tim mạch luôn là một trong những thách thức y tế lớn nhất trên toàn cầu, đòi hỏi sự can thiệp và chẩn đoán kịp thời, chính xác. Trong bối cảnh đó, điện tâm đồ (ECG) 12 chuyển đạo vẫn đóng vai trò là tiêu chuẩn vàng trong quy trình khám chữa bệnh lâm sàng. Tuy nhiên, việc đọc hiểu và phân tích các bản ghi ECG đa bệnh lý, có sự chồng lấp dấu hiệu luôn đặt ra một áp lực khổng lồ lên đội ngũ y bác sĩ. Xuất phát từ nhu cầu cấp thiết đó, đồ án đã nghiên cứu, thiết kế và phát triển thành công hệ thống Cardiac AI V4 – một giải pháp công nghệ y tế (HealthTech) toàn diện hỗ trợ chẩn đoán 27 bệnh lý tim mạch phức tạp.

Điểm đột phá cốt lõi của công trình nằm ở việc đề xuất một kiến trúc học sâu lai (Hybrid Deep Learning) tiên tiến, kết hợp hoàn hảo giữa mạng tích chập đa tỷ lệ (Multi-scale CNN) và khối Transformer Encoder. Nếu như CNN đóng vai trò như một thấu kính vi mô để bắt trọn những biến đổi hình thái sắc nét của phức tạp QRS, thì cơ chế Self-Attention của Transformer lại cung cấp một góc nhìn vĩ mô, nắm bắt sự phụ thuộc xa về mặt chu kỳ nhịp tim. Sự kết hợp này đã giúp mô hình vượt qua những rào cản của các phương pháp truyền thống, đạt được hiệu năng ấn tượng trên tập dữ liệu quy mô lớn PhysioNet 2020 với chỉ số diện tích dưới đường cong (AUC) lên tới 0.921 và Mean Average Precision (mAP) đạt 0.517 trên tập kiểm thử hoàn toàn độc lập.

Không dừng lại ở những con số toán học khô khan, giá trị thực tiễn và tính nhân văn của đồ án được thể hiện rõ nét qua việc đưa tư duy y khoa vào cốt lõi hệ thống. Việc mạnh dạn từ bỏ ngưỡng phân loại mặc định để xây dựng ba chiến lược tối ưu ngưỡng độc lập (Youden, tối ưu F1 kết hợp ràng buộc Recall an toàn, và ngưỡng Sàng lọc) đã minh chứng cho sự am hiểu sâu sắc về rủi ro y tế. Cardiac AI V4 không chỉ là một mô hình phân loại đa nhãn xuất sắc, mà còn là một tấm màng lọc an toàn, ưu tiên tuyệt đối việc không bỏ sót các ca bệnh đe dọa đến tính mạng.

Kết quả cuối cùng của đồ án là một phần mềm hỗ trợ chẩn đoán với giao diện trực quan, chuyên nghiệp, sẵn sàng tiếp nhận tín hiệu ECG nguyên bản và đưa ra các báo cáo y khoa đa chiều. Mặc dù vẫn còn những hạn chế nhất định về tính diễn giải (XAI) hay nhu cầu tối ưu hóa phần cứng, nhưng những thành tựu đạt được đã khẳng định tính đúng đắn của phương pháp tiếp cận. Cardiac AI V4 không mang tham vọng thay thế các chuyên gia y tế, mà định vị bản thân như một người trợ lý "ý kiến thứ hai" (second opinion) đáng tin cậy, bền bỉ và chính xác. Đồ án kỳ vọng đây sẽ là một viên gạch nền tảng vững chắc, góp phần thúc đẩy công cuộc chuyển

đổi số trong lĩnh vực y tế thông minh và nâng cao chất lượng chăm sóc sức khỏe cộng đồng trong tương lai.

Lời cuối cùng, em xin được dành sự trân trọng và lòng biết ơn sâu sắc nhất gửi tới TS. Trần Văn Thiện – người thầy đã trực tiếp hướng dẫn, dìu dắt và đồng hành cùng em trong suốt quá trình nghiên cứu và thực hiện đồ án này. Thầy không chỉ là người định hướng con đường khoa học, truyền đạt những kiến thức chuyên môn quý báu, mà còn luôn kiên nhẫn lắng nghe, tận tình gỡ rối và động viên em vượt qua những giai đoạn bế tắc nhất khi xây dựng và tối ưu hệ thống. Chính sự tâm huyết, sự khắt khe trong chuẩn mực học thuật cùng ngọn lửa đam mê nghiên cứu từ thầy đã trở thành nguồn động lực to lớn, giúp em có đủ niềm tin và sự kiên trì để hoàn thiện trọn vẹn đề tài. Em xin kính chúc thầy luôn dồi dào sức khỏe, bình an và tiếp tục gặt hái thêm nhiều thành tựu rực rỡ trên con đường sự nghiệp trồng người và nghiên cứu khoa học.

Em xin chân thành cảm ơn!

TÀI LIỆU THAM KHẢO

[1] Bruoth, J., & cộng sự. (2021). *Cardiac arrhythmia classification using deep learning and random forest*. In Proceedings of the 2021 Computing in Cardiology. IEEE.

[2] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, *16*, 321-357. https://doi.org/10.1613/jair.953

[3] Donnelly, K. (2006). SNOMED-CT: The advanced terminology and coding system for eHealth. *Studies in Health Technology and Informatics*, *121*, 279-290.

[4] Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., & Houlsby, N. (2021). An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations (ICLR)*.

[5] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press.

[6] Hannun, A. Y., Rajpurkar, P., Haghpanahi, M., Tison, G. H., Bourn, C., Turakhia, M. P., & Ng, A. Y. (2019). Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network. *Nature Medicine*, *25*(1), 65-69. https://doi.org/10.1038/s41591-018-0268-3

[7] Hinton, G., Vinyals, O., & Dean, J. (2015). Distilling the knowledge in a neural network. *arXiv preprint arXiv:1503.02531*. https://doi.org/10.48550/arXiv.1503.02531

[8] Hong, S., Zhou, Y., Shang, J., Xiao, C., & Sun, J. (2020). Opportunities and challenges of deep learning methods for electrocardiogram data: A systematic review. *Computers in Biology and Medicine*, *122*, 103801. https://doi.org/10.1016/j.compbiomed.2020.103801

[9] Lin, T. Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal loss for dense object detection. In *Proceedings of the IEEE International Conference on Computer Vision* (pp. 2980-2988).

[10] Lipton, Z. C., Elkan, C., & Naryanaswamy, B. (2014). Optimal thresholding of classifiers to maximize F1 measure. In *Machine Learning and Knowledge Discovery in Databases: European Conference, ECML PKDD 2014* (pp. 225-239). Springer.

[11] Natarajan, A., Chang, Y., Mariani, S., Rahman, A., Boverman, G., Vij, S., & Rubin, J. (2020). A wide and deep transformer neural network for 12-lead ECG classification. In *2020 Computing in Cardiology* (pp. 1-4). IEEE. https://doi.org/10.22489/CinC.2020.106

[12] Pan, J., & Tompkins, W. J. (1985). A real-time QRS detection algorithm. *IEEE Transactions on Biomedical Engineering*, (3), 230-236. https://doi.org/10.1109/TBME.1985.325532

[13] Perez Alday, E. A., Gu, A., Shah, A. J., Robichaux, C., Wong, A. K. I., Liu, C., Liu, F., Rad, A. B., Elola, A., Seyedi, S., Li, Q., Sharma, A., Clifford, G. D., & Reyna, M. A. (2021). Classification of 12-lead ECGs: The PhysioNet/Computing in Cardiology Challenge 2020. *Physiological Measurement*, *41*(12), 124003. https://doi.org/10.1088/1361-6579/abc960

[14] Phan, T., Le, D., & Le, N. T. H. (2022). Multimodality multi-lead ECG arrhythmia classification using self-supervised learning. In *2022 IEEE-EMBS International Conference on Biomedical and Health Informatics (BHI)* (pp. 1-4). IEEE. https://doi.org/10.1109/BHI56158.2022.9926744

[15] Ridnik, T., Ben-Baruch, E., Zamir, N., Noy, A., Friedman, I., Protter, M., & Zelnik-Manor, L. (2021). Asymmetric loss for multi-label classification. In *Proceedings of the IEEE/CVF International Conference on Computer Vision* (pp. 82-91).

[16] Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. In *Proceedings of the IEEE International Conference on Computer Vision* (pp. 618-626).

[17] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, *30*.

[18] Wagner, P., Strodthoff, N., Bousseljot, R. D., Kreiseler, D., Lunze, F. I., Samek, W., & Schaeffter, T. (2020). PTB-XL, a large publicly available electrocardiography dataset. *Scientific Data*, *7*(1), 1-15. https://doi.org/10.1038/s41597-020-0495-6

[19] Wang, Z., & Bovik, A. C. (2002). A universal image quality index. IEEE Signal Processing Letters, 9(3), 81-84.

[20] Youden, W. J. (1950). Index for rating diagnostic tests. *Cancer*, *3*(1), 32-35. https://doi.org/10.1002/1097-0142(1950)3:1<32::AID-CNCR2820030106>3.0.CO;2-3